IF69D-S11 e OPEET014-OPEL
Processamento Digital de Imagens

Aula 05 – Image Enhancement in the space domain

Adptative filters & Image Quality Metrics

Universidade Tecnológica Federal do Paraná – UTFPR
Prof. Humberto R. Gamba e Prof. Gustavo B. Borba

22.set.2026

Exemplo de um filtro linear no ‘baixo nível’ (operação correlação)

```
% 3x3 box filter
mask = [1/9 1/9 1/9;...
        1/9 1/9 1/9;...
        1/9 1/9 1/9];
gf = zeros(nr,nc);
tic
for i = 2 : nr-1
  for j = 2 : nc-1
    gf(i,j)  =  mask(1,1)*g(i-1,j-1) + ...

                mask(1,2)*g(i-1,j) + ...

                mask(1,3)*g(i-1,j+1) + ...

                mask(2,1)*g(i,j-1) + ...

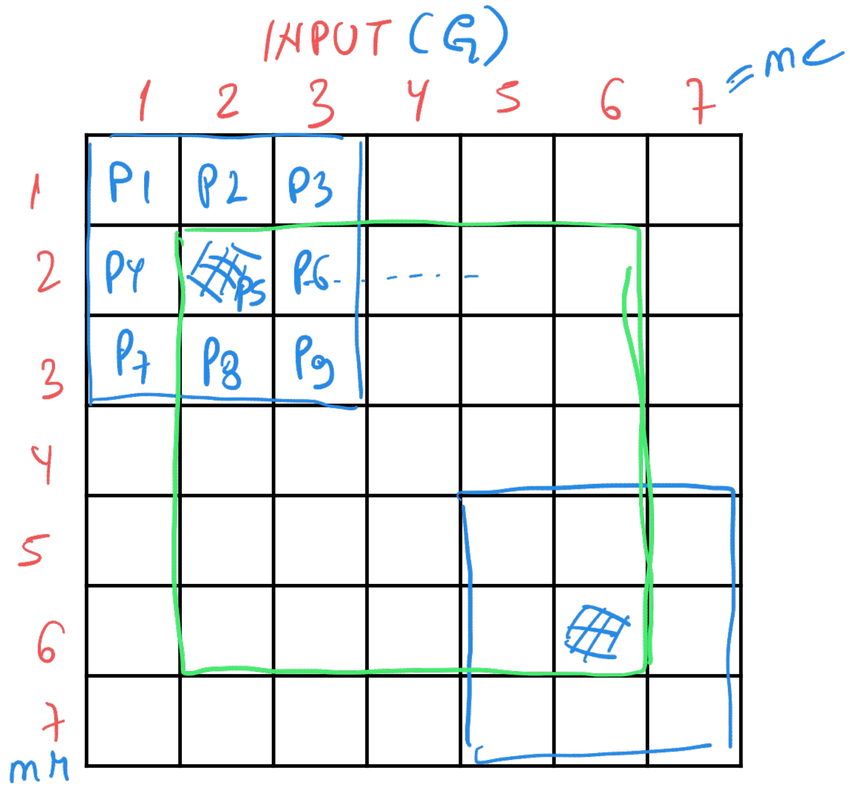
                mask(2,2)*g(i,j) + ...

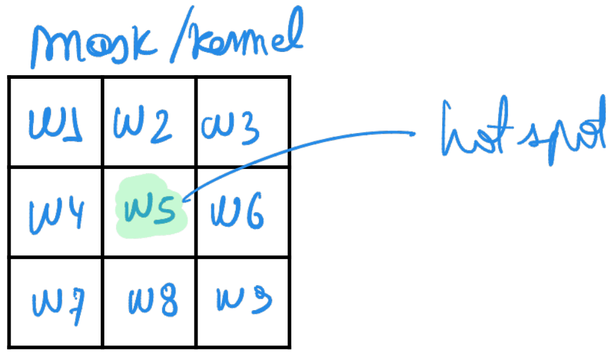
                mask(2,3)*g(i,j+1) + ...

                mask(3,1)*g(i+1,j-1) + ...

                mask(3,2)*g(i+1,j) + ...

                mask(3,3)*g(i+1,j+1);
  endfor
endfor
t1 = toc
```





Separabilidade dos filtros lineares

$$H = \frac{1}{9}\begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix} = \begin{bmatrix} 1/3 \\ 1/3 \\ 1/3 \end{bmatrix} \cdot \begin{bmatrix} 1/3 & 1/3 & 1/3 \end{bmatrix}$$

H_x · H_y (produto externo / outer product)

BOX FILTER 3×3

2D direto 3×3 = 9 operações

$$I * H_{xy} = I * (H_x * H_y)$$

$$I * H_x * H_y$$

3 operações + 3 operações } 6 operações

A máscara 2D pode ser construída como um produto externo de dois vetores 1D

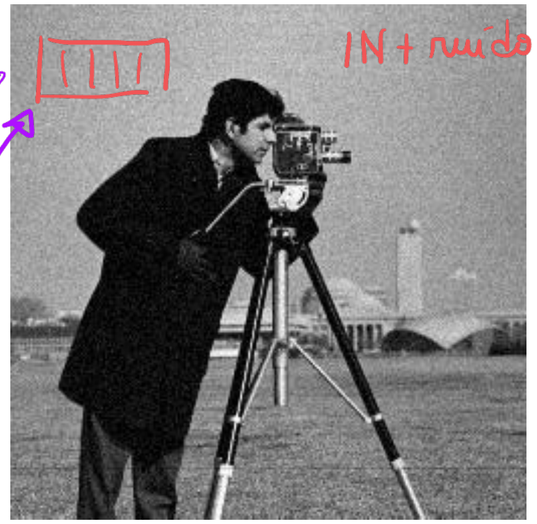
A separabilidade transf um problema 2D em dois problemas 1D

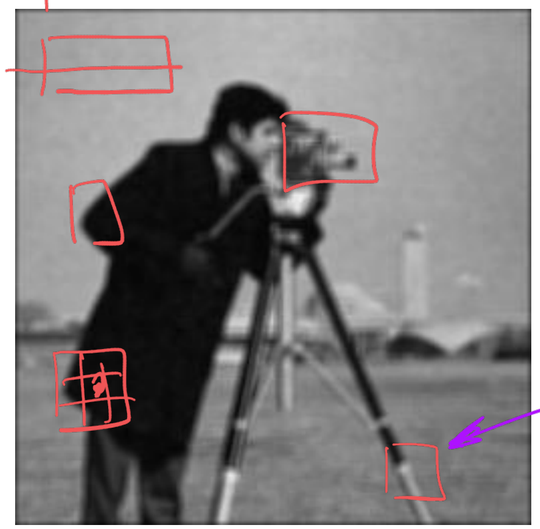
kernel	mas separado	separado
3×3	9 operações	6 operações
5×5	25 "	10 operações
7×7	49 "	14 operações
	quadrática	linear

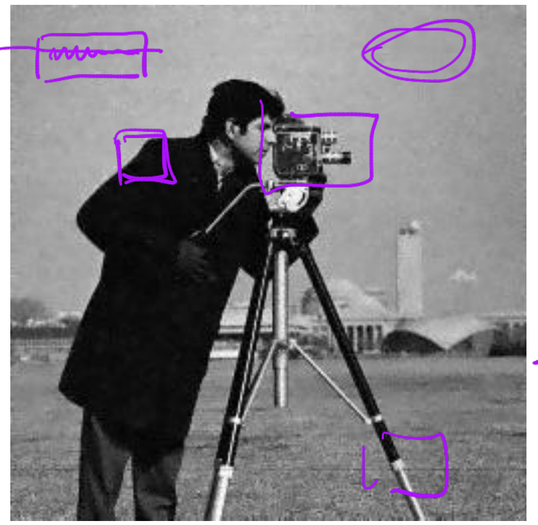
Edge-preserving filters

- Aplicação típica: redução de ruído com preservação das bordas e detalhes finos da imagem. Também chamados de *filtros adaptativos*









Edge-preserving filters

$$A = \left(1 - \frac{V_R}{V_L}\right) p + \frac{V_R}{V_L} \cdot m_L$$

OUTPUT

V_R → variância do ruído

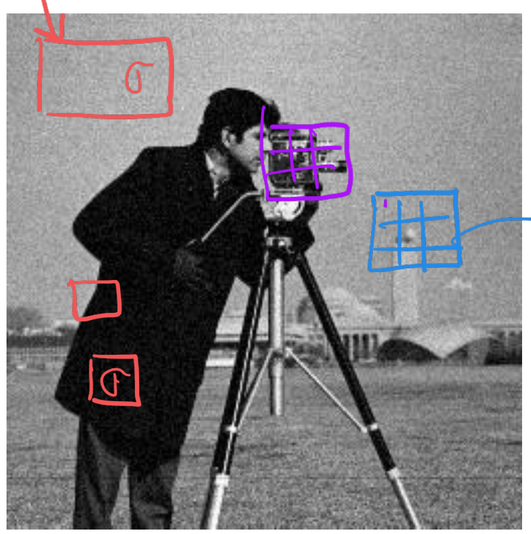
V_L → variância local

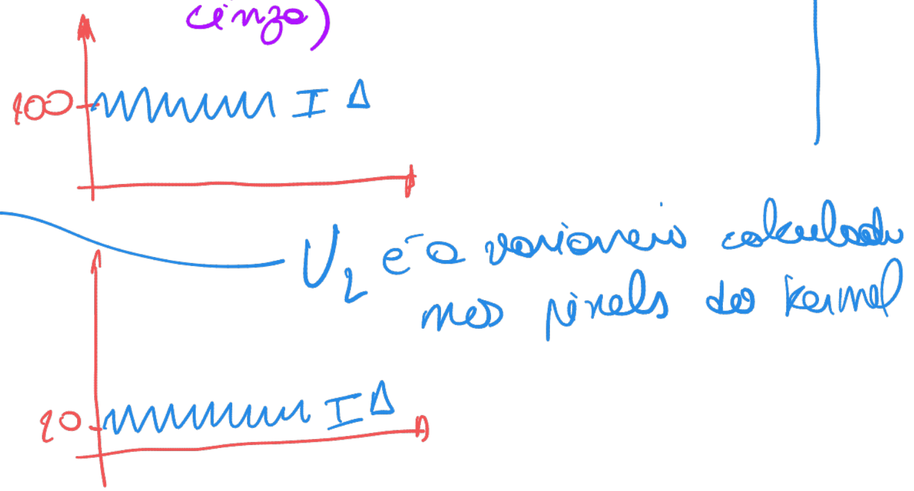
p → pixel central / hot spot do kernel

m_L → média local (dentro do kernel)

V_R → variância do ruído
Lo é uma constante em toda a imagem

Deve ser medido em uma região uniforme (tom de cinza)





(i) regiões homogêneas (canto superior esquerdo), nessa região o filtro adaptativo deve atuar como o box filter

$$V_L \approx V_R \rightarrow \frac{V_R}{V_L} \approx 1$$

$$A = (1 - 1)\,p + 1 \cdot m_L = m_L$$

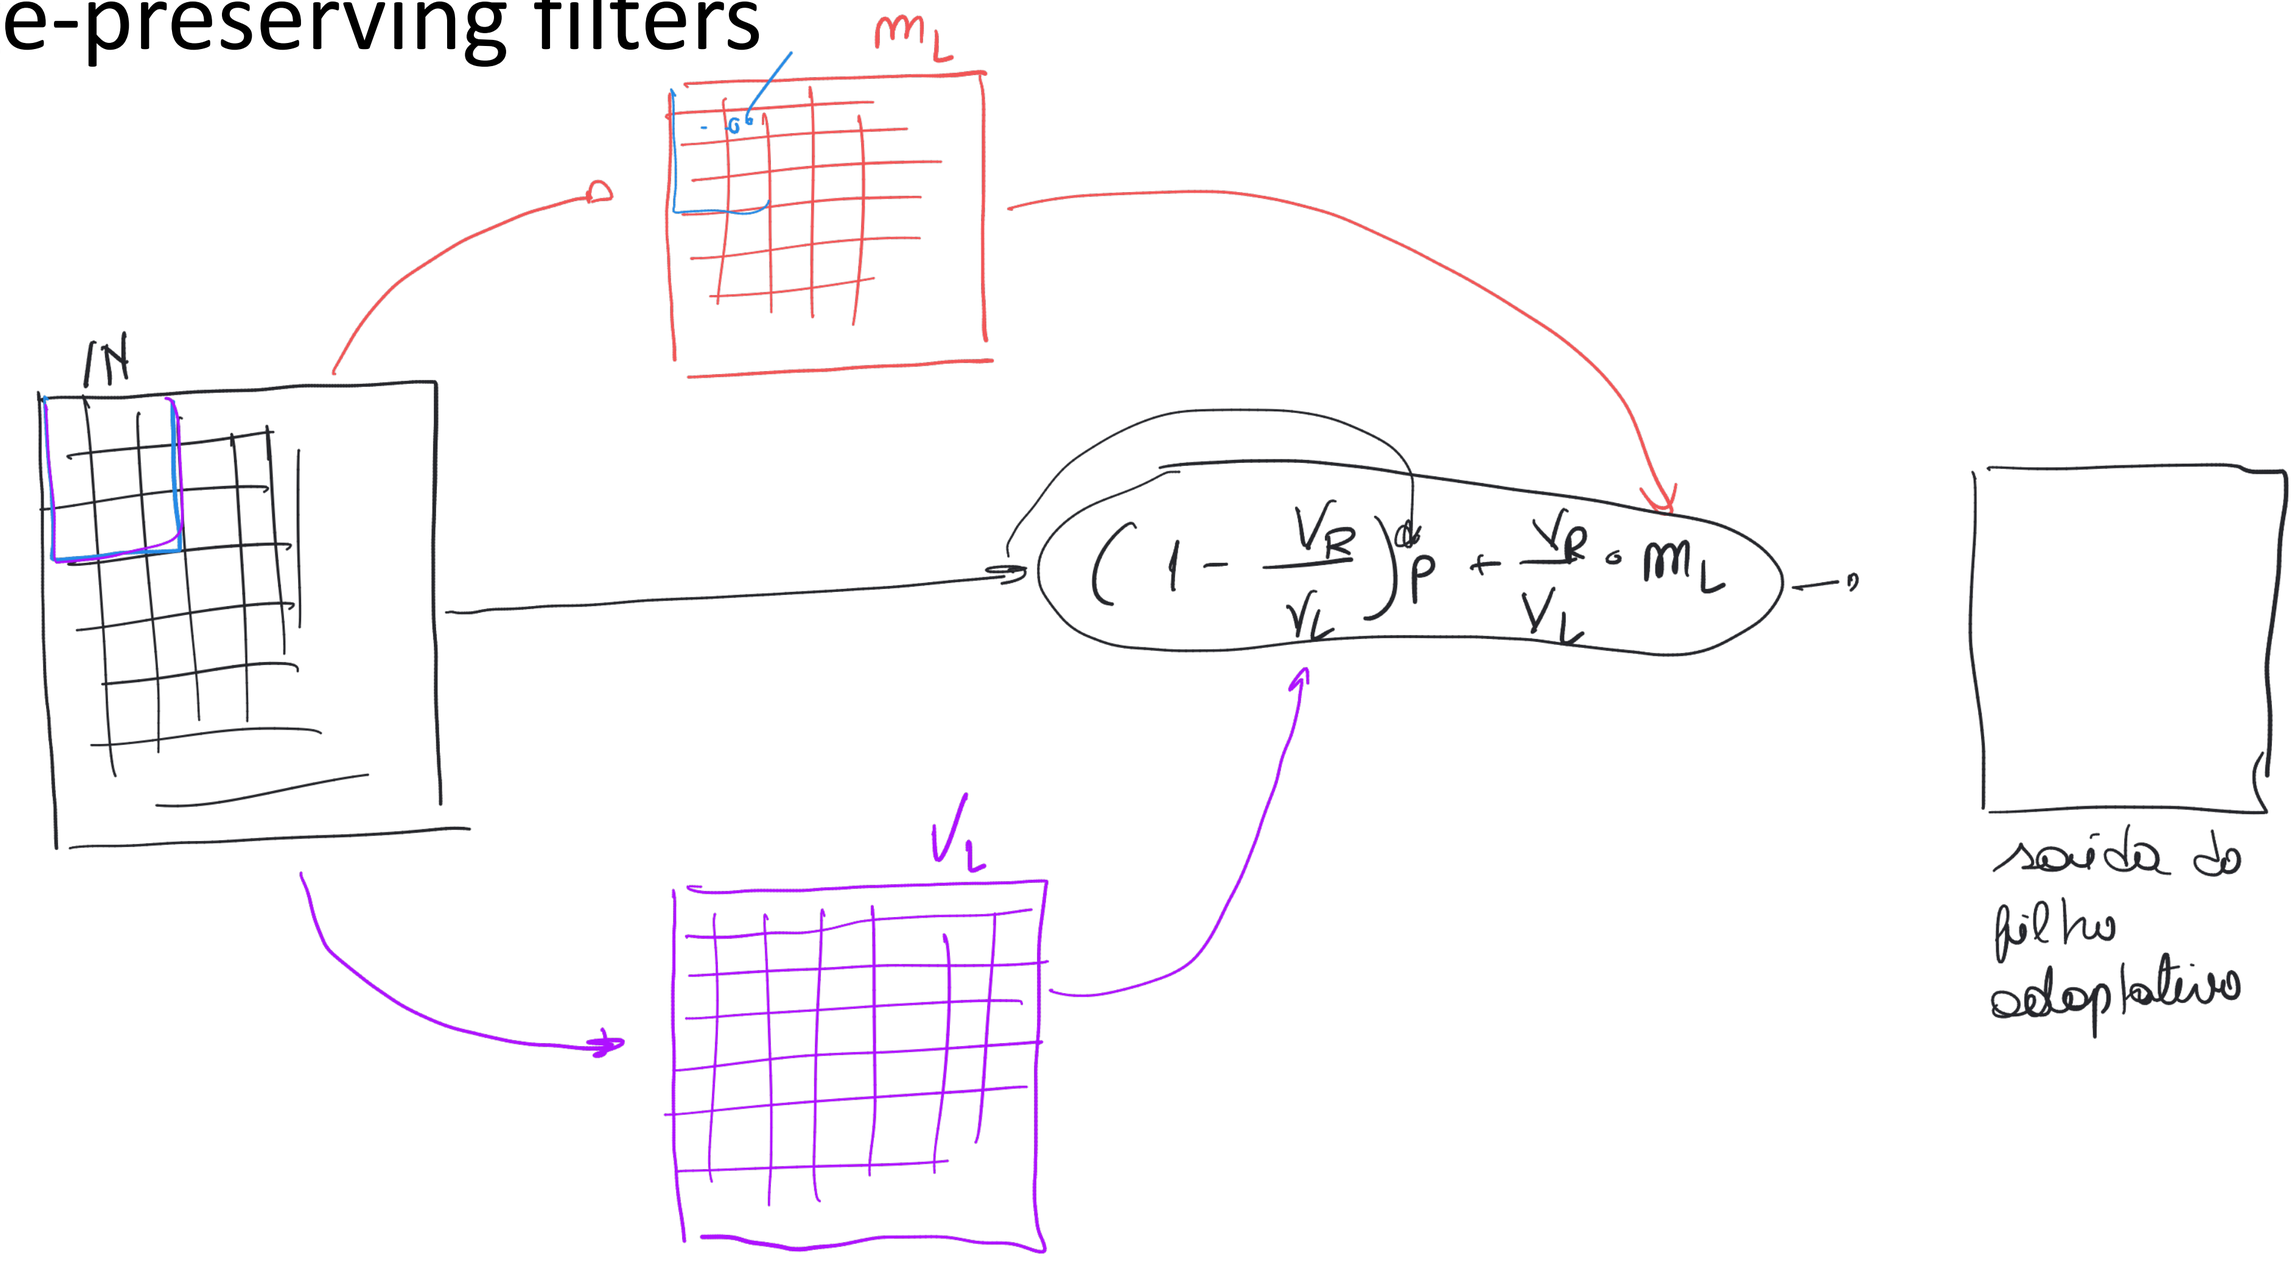
(ii) regiões com muito detalhes ou bordas

$$V_L \gg V_R \rightarrow \frac{V_R}{V_L} \rightarrow 0$$

$$A = (1 - 0)\,p + 0 \cdot m_L = p$$

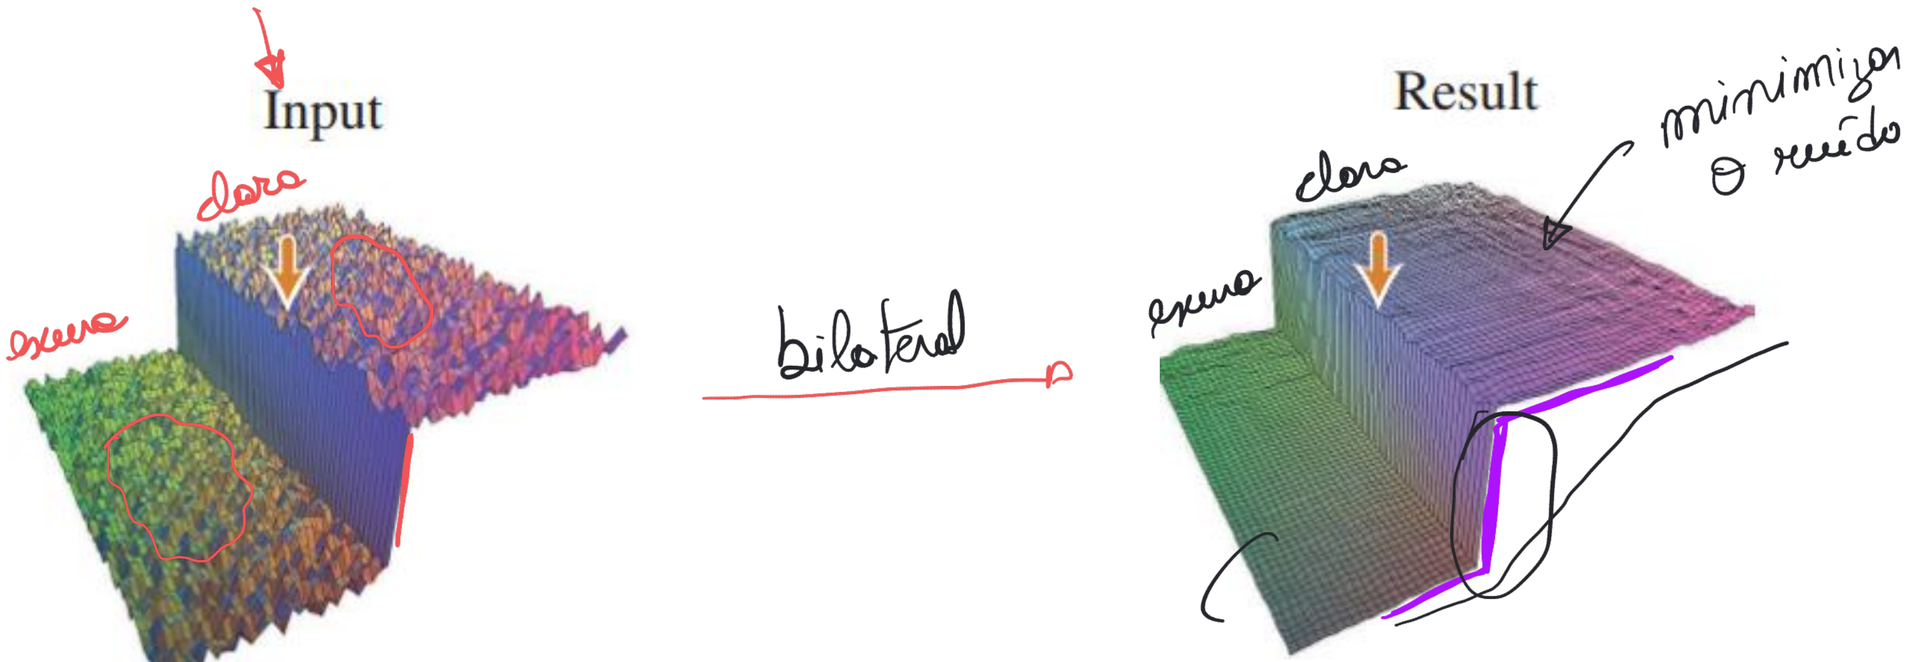
nessas regiões mantém-se o valor do pixel da imagem de entrada

Edge-preserving filters



Bilateral filter

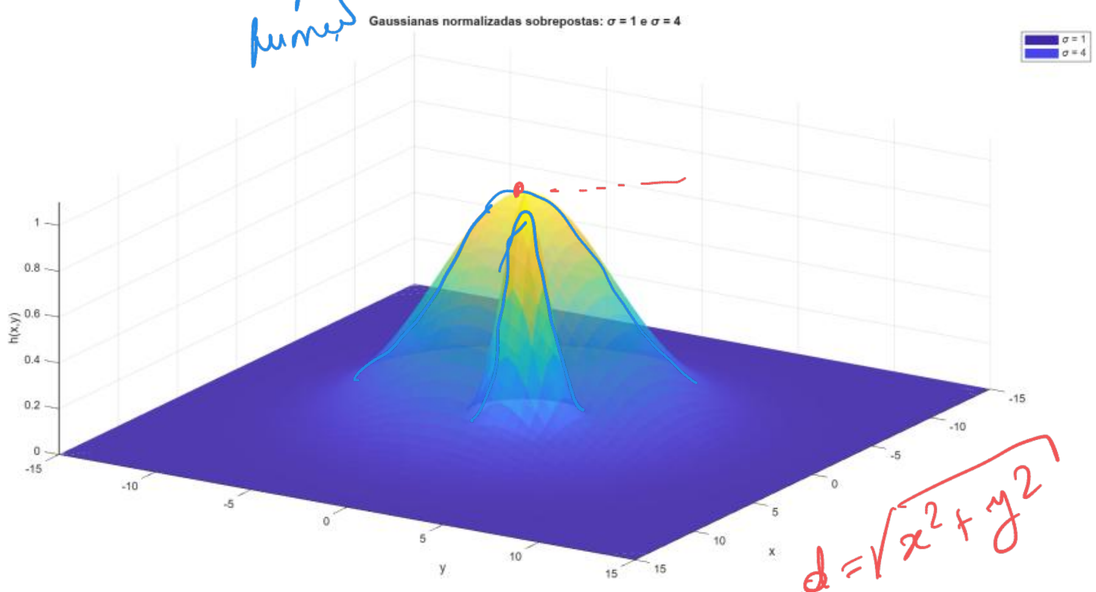
- É um *edge-preserving filter*
- Baseado em *Gaussian kernels*



O filtro bilateral faz uma média ponderada dos pixels vizinhos, mas um pixel só recebe peso alto se estiver próximo espacialmente **E** tiver intensidade semelhante ao pixel central.

Bilateral filter

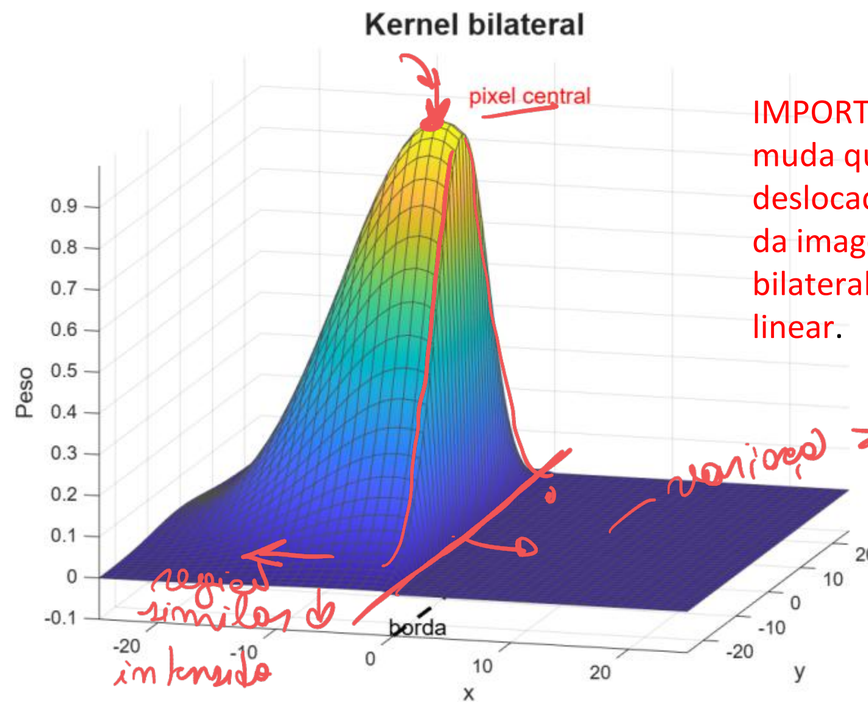
Filtro Gaussiano:
Peso = f(distância do pixel central)



$$Gs(x,y) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{x^2+y^2}{2\sigma^2}}$$

Bilateral filter:

$$Peso = proximidade\ espacial \times similaridade\ de\ intensidade$$



IMPORTANTE: Essa forma muda quando o kernel é deslocado para outro ponto da imagem, por isso o bilateral não é um filtro linear.

$$w(i,j\,;\,m,n) = Gs(d) \times Gr(\Delta I)$$

- No filtro Gaussiano, o peso depende apenas da distância ao pixel central.
- No bilateral, o peso depende da distância e da semelhança de intensidade.

Assim, pixels próximos mas do outro lado de uma borda, recebem peso muito pequeno.

Bilateral filter

Gaussiana de intensidade G_r

Gaussiana especial: baseada na distância euclediana $d^2 = m - j^2 + (n - j)^2$

$$G_s(x,y) = \frac{1}{\sqrt{2\pi\sigma_s^2}} e^{-\frac{x^2+y^2}{2\sigma_s^2}}$$

Na Gaussiana de intensidade, substituímos a distância espacial pela diferença de intensidade em relação ao pixel central.

$$G_r(\Delta I) = \frac{1}{\sqrt{2\pi\sigma_r^2}} e^{-\frac{\Delta I^2}{2\sigma_r^2}}$$

onde $\Delta I = f(m,n) - f(i,j)$, diferença de intensidade do pixel vizinho e do pixel central

G_s : distância em posição(s=spacial)

G_r : distância em intensidade (r=range)

Exemplo:

$$f(i,j) = 100$$

$$f(m_1, n_1) = 105 \quad \Rightarrow \quad \Delta I = 5$$

$$f(m_2, n_2) = 180 \quad \Rightarrow \quad \Delta I = 80$$

$$G_r(\Delta I) = \frac{1}{\sqrt{2\pi\sigma_r^2}} e^{-\frac{\Delta I^2}{2\sigma_r^2}}$$

$Gr(5) \approx 1$ $\qquad$ $Gr(80) \approx 0$

$$w(i,j\,;\,m,n) = Gs(d) \times Gr(\Delta I)$$

funções de similaridade

Bilateral filter

Gaussiana de intensidade: escolha de σ_r

$$G_r(\Delta I) = e^{-\frac{\Delta I^2}{2\sigma_r^2}}$$

$\frac{1}{\sqrt{2\pi\sigma_r^2}}$ é uma constante

σ_r controla a tolerância à diferença de intensidade:

- σ_r pequeno → só pixels com intensidade muito próxima do pixel central recebem peso alto
- σ_r grande → pixels com diferenças maiores de intensidade participam da média

$$\Delta I = \sigma_r \rightarrow G_r \approx 0{,}61$$
$$\Delta I = 2\sigma_r \rightarrow G_r \approx 0{,}14$$
$$\Delta I = 3\sigma_r \rightarrow G_r \approx 0{,}01$$

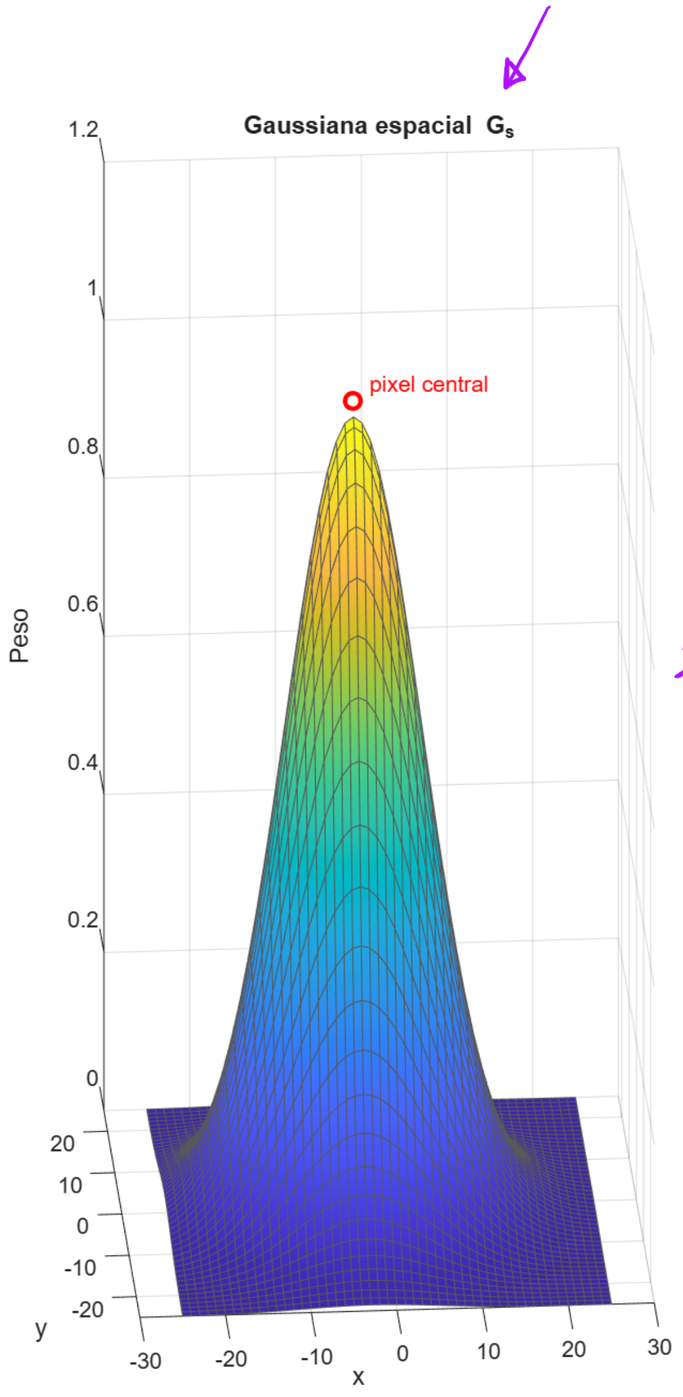
Gr atua como um **fator modulador** da gaussiana espacial Gs

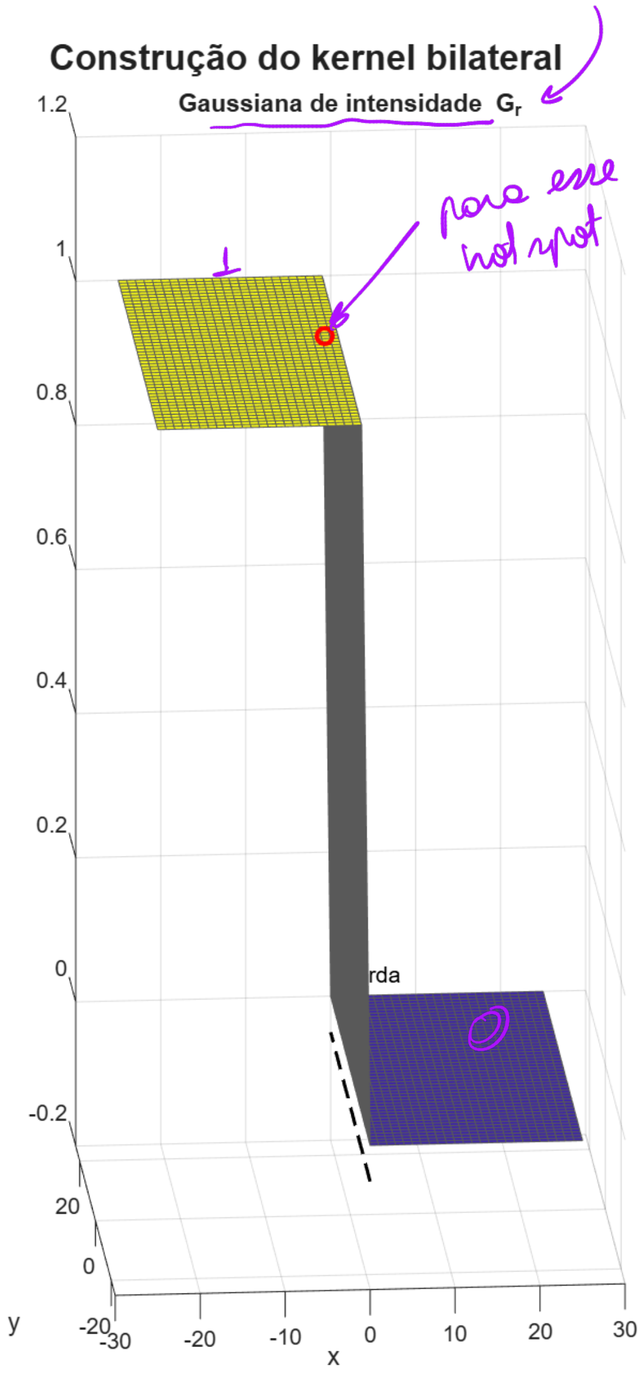
Escolha de σ_r: define a diferença de intensidade considerada aceitável.

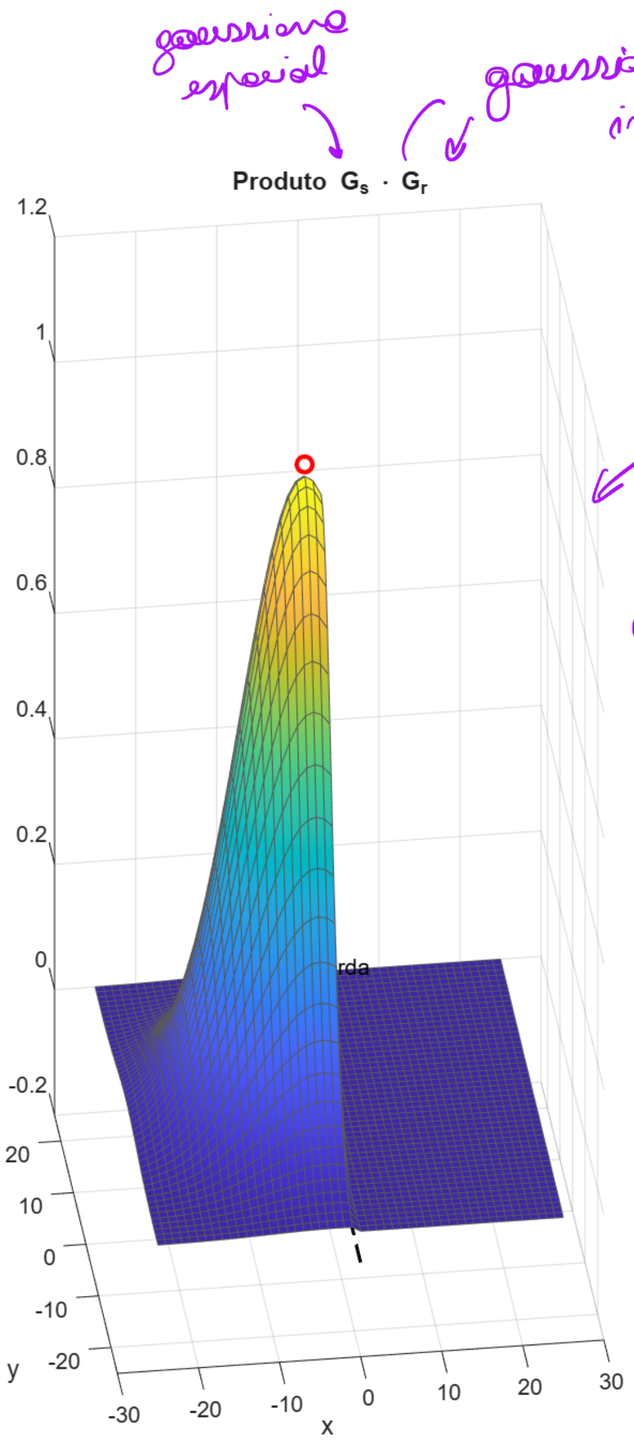
Quanto menor σ_r, maior a preservação de bordas.

Quanto maior σ_r, maior a suavização e menor a preservação de bordas.

Bilateral filter

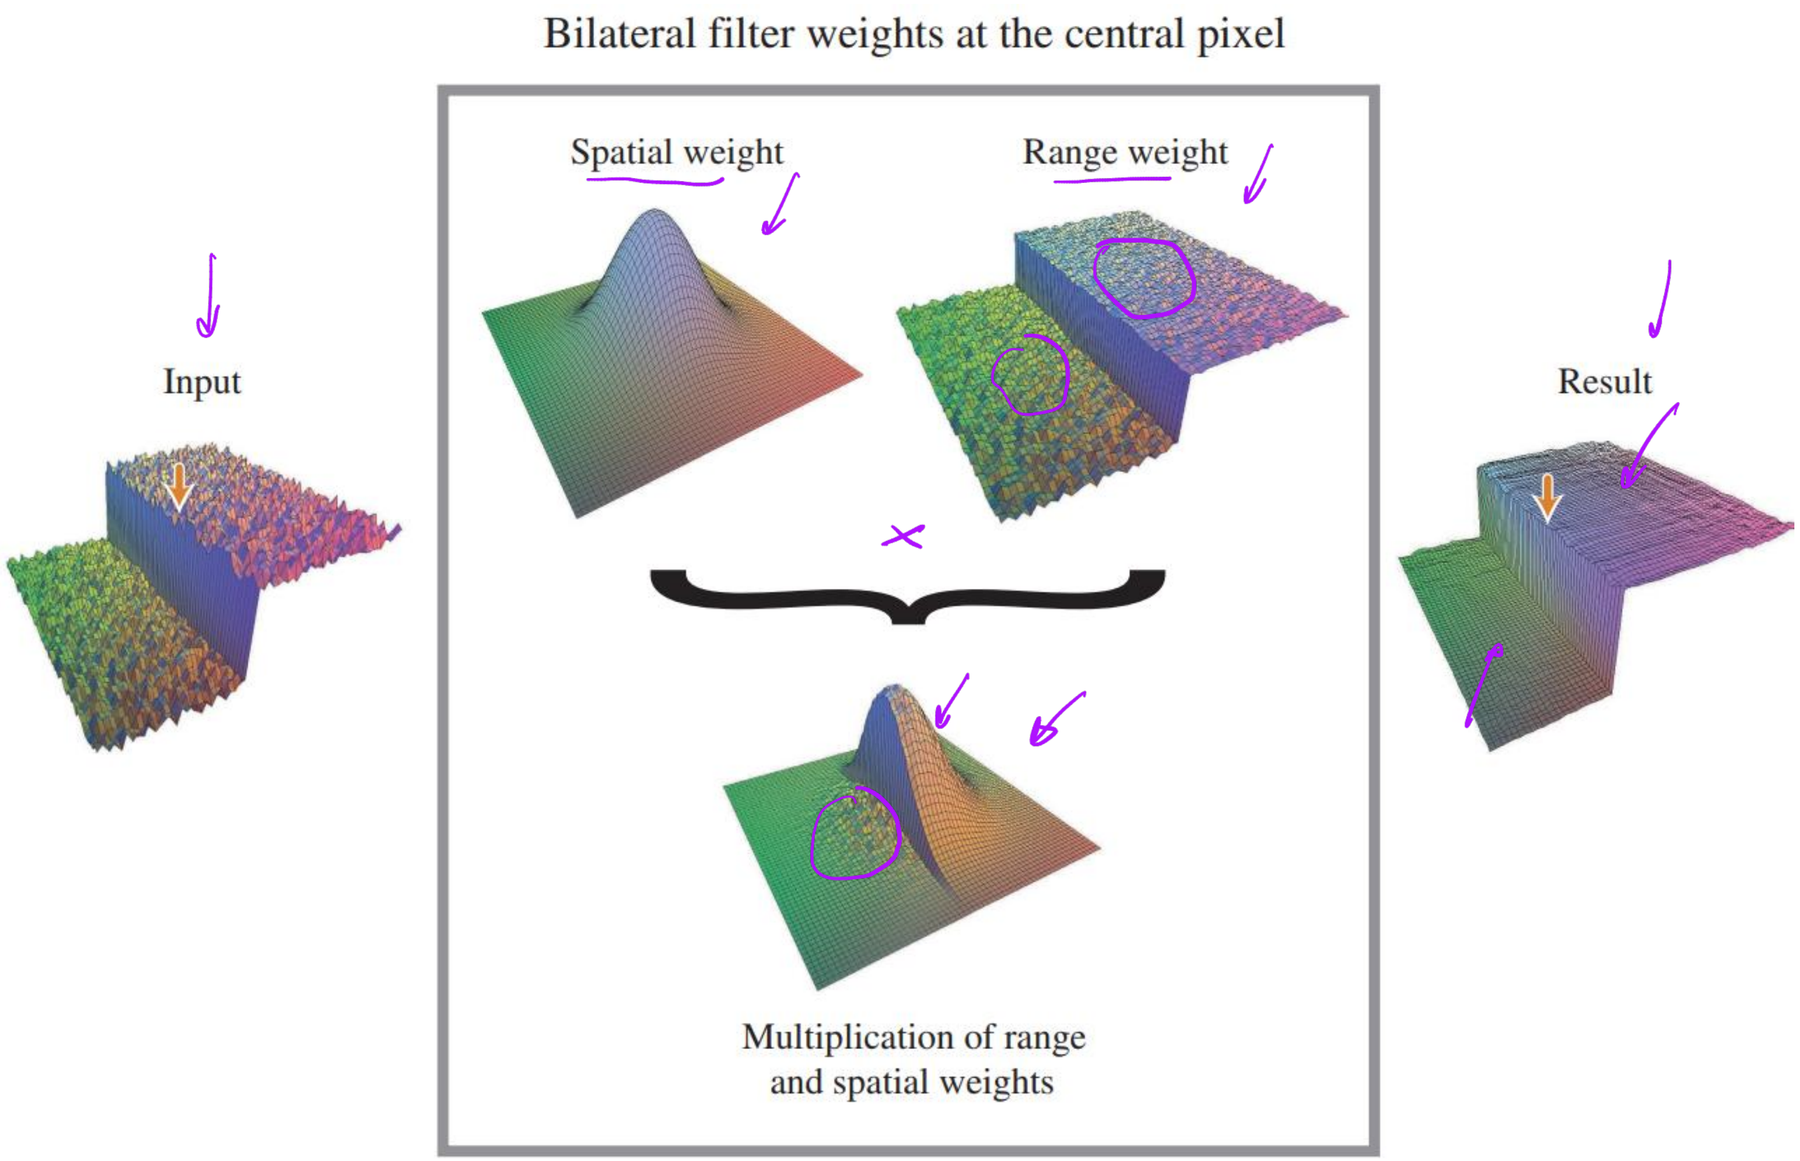






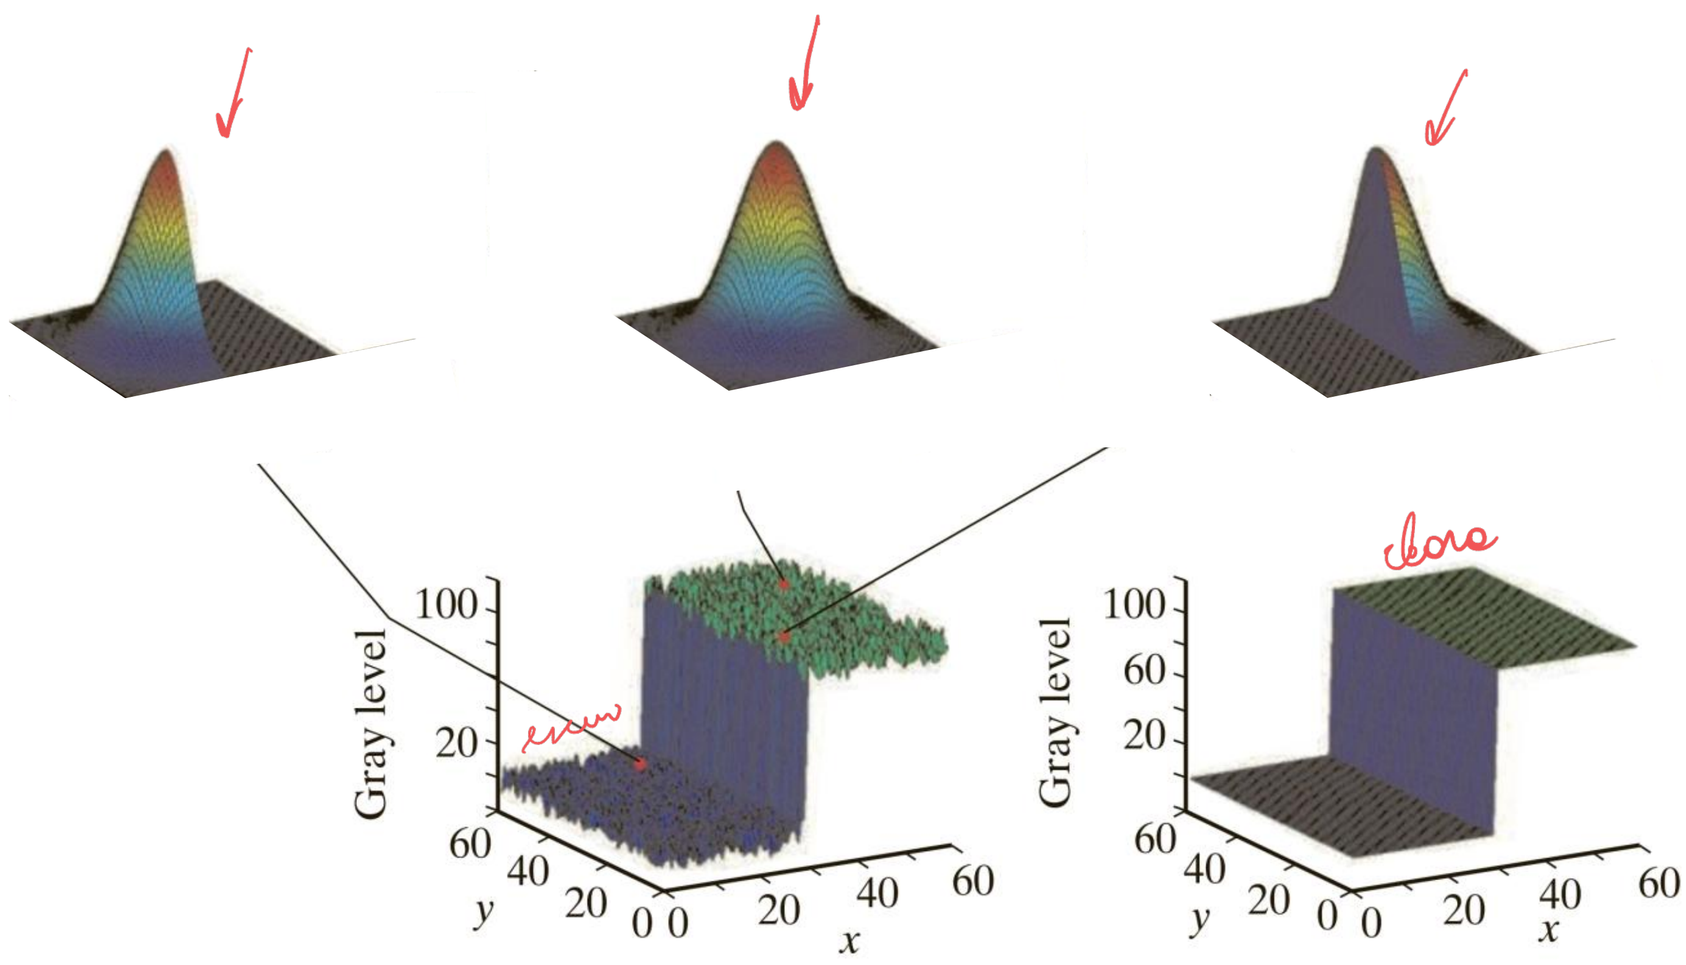
Bilateral filter

- O bilateral é baseado em duas *Gaussian kernels*



S. Paris, P. Kornprobst, J. Tumblin and F. Durand, Bilateral Filtering: Theory and Applications, Foundations and Trends in Computer Graphics and Vision, Vol. 4, No. 1 (2008) 1–73. 2009.
Disponível em https://www.researchgate.net/publication/220427978_Bilateral_Filtering_Theory_and_Applications 840+ citações segundo o Scholar

Bilateral filter



Stan Birchfield, Image Processing and Analysis, Cengage Learning, 2018, Figura 5.17.

Bilateral filter

Comparação: filtro da média e filtro bilateral

Imagem original



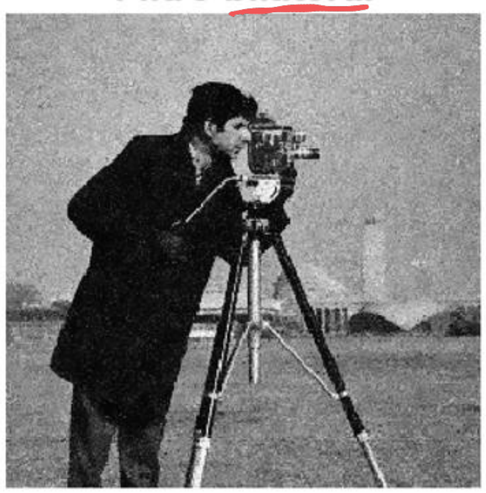
Imagem com ruído gaussiano



Filtro da média 5 × 5



Filtro bilateral



ZOOM

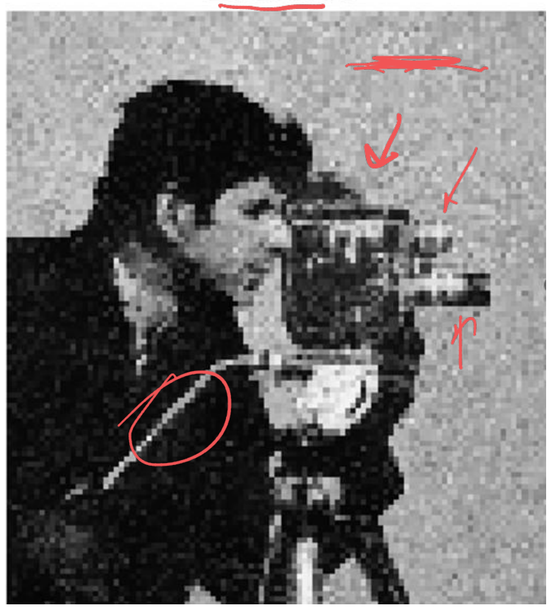
Com ruído



Média 5 × 5



Bilateral



Bilateral filter: MATLAB

21:05

21:20

J = imbilatfilt(I, degreeOfSmoothing, spatialSigma)

- I: imagem de entrada;
- degreeOfSmoothing: controla a tolerância à diferença de intensidade, isto é, está associado ao termo G_r;
- spatialSigma: controla a extensão espacial da Gaussiana G_s.

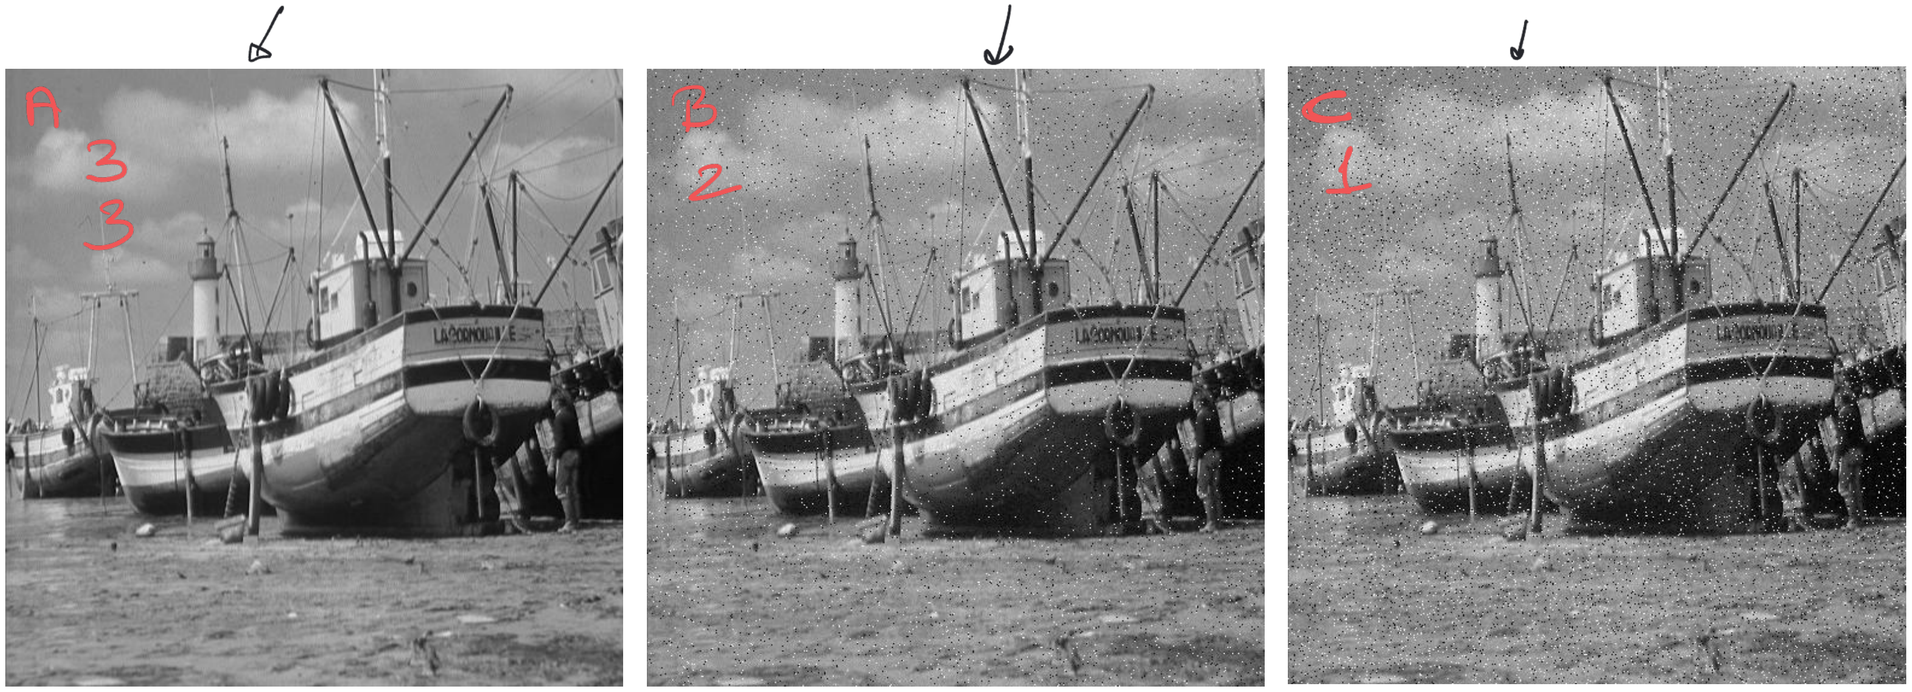
Um detalhe importante: no MATLAB, degreeOfSmoothing não é passado diretamente como σ_r. Ele funciona como um parâmetro de suavização associado à variância no domínio da intensidade

```
I = im2double(imread('cameraman.tif'));

sigma_r = 0.10; % similaridade de intensidade
sigma_s = 3;    % distância espacial

J = imbilatfilt(I, sigma_r^2, sigma_s);
```

Image Quality Metrics - IQM (métricas objetivas de qualidade de imagem)



MEAN OPINION SCORE(MOS): quantitativo, subjetivo

outros métodos: quantitativos, objetivos

- FULL-REFERENCE (FR)
  tenho a imagem original para comparar
- NO-REFERENCE
  não tenho a imagem original para comparar

Imagem boat.512.tiff disponível em http://sipi.usc.edu/database/

Image Quality Metrics
MSE: mean squared error (full-reference)

$$MSE = \frac{\sum_{i=1}^{M}\sum_{j=1}^{N}(f(i,j) - \hat{f}(i,j))^2}{MN}$$



Imagem boat.512.tiff disponível em http://sipi.usc.edu/database/

Image Quality Metrics

PSNR: peak signal-to-noise ratio (full-reference)

SNR = sinal / ruído ↑

qto maior melhor

$$PSNR = 20 log \frac{L}{\sqrt{\sum_{i=1}^{M}\sum_{j=1}^{N}\frac{(\hat{f}(i,j)-f(i,j))^2}{MN}}} [dB]$$

L: 8 bpp = 256

$\sqrt{\text{MSE}}$



REF → MSE = 0

PSNR → ∞

qto maior o PSNR melhor



PSNR = 22 dB



PSNR = 18 dB

Imagem boat.512.tiff disponível em http://sipi.usc.edu/database/

Image Quality Metrics
SSIM: structural similarity index (full-reference)

SSIM mede erro, mede similaridade | MSE mede diferença entre pixel

SSIM compara como as imagens estão "organizadas"

For luminance comparison, we define

média das imagens

se $\mu_x = \mu_y \rightarrow l = 1$

se $\mu_x \neq \mu_y$ $l < 1$

$$l(\mathbf{x}, \mathbf{y}) = \frac{2\mu_x\mu_y + C_1}{\mu_x^2 + \mu_y^2 + C_1} \tag{6}$$

where the constant C_1 is included to avoid instability when $\mu_x^2 + \mu_y^2$ is very close to zero. Specifically, we choose

$$C_1 = (K_1 L)^2$$

where L is the dynamic range of the pixel values (255 for 8-bit grayscale images), and $K_1 \ll 1$ is a small constant.

The contrast comparison function takes a similar form

$$c(\mathbf{x}, \mathbf{y}) = \frac{2\sigma_x\sigma_y + C_2}{\sigma_x^2 + \sigma_y^2 + C_2} \tag{9}$$

mede o variável de contraste entre as imagens x e y

where $C_2 = (K_2 L)^2$, and $K_2 \ll 1$.

we define the structure comparison function as follows:

$s = 1$ estruturas iguais

$s < 1$ estruturas diferentes

covariância

$$s(\mathbf{x}, \mathbf{y}) = \frac{\sigma_{xy} + C_3}{\sigma_x\sigma_y + C_3} \tag{10}$$

mede a correlação entre pixels

Finally, we combine the three comparisons of (6), (9) and (10) and name the resulting similarity measure the SSIM index between signals $\mathbf{x}$ and $\mathbf{y}$

$$\mathrm{SSIM}(\mathbf{x}, \mathbf{y}) = [l(\mathbf{x}, \mathbf{y})]^{\alpha} \cdot [c(\mathbf{x}, \mathbf{y})]^{\beta} \cdot [s(\mathbf{x}, \mathbf{y})]^{\gamma}$$

luminância · contraste · estrutura

o resultado = l . c . s

$\alpha = \beta = \gamma = 1$ $\quad C_3 = C_2/2 \quad$ $K_1 = 0.01; K_2 = 0.03$

$$\mu_x = \frac{1}{N}\sum_{i=1}^{N} x_i \qquad \sigma_x = \left(\frac{1}{N-1}\sum_{i=1}^{N}(x_i - \mu_x)^2\right)^{\frac{1}{2}}$$

$$\sigma_{xy} = \frac{1}{N-1}\sum_{i=1}^{N}(x_i - \mu_x)(y_i - \mu_y)$$

SSIM = 1 idênticos

SSIM entre 0,8 e 1 muito semelhantes

SSIM < 0,5 bem diferentes

Zhou Wang, A. C. Bovik, H. R. Sheikh and E. P. Simoncelli, **Image quality assessment: from error visibility to structural similarity**, in *IEEE Transactions on Image Processing*, vol. 13, no. 4, pp. 600-612, April 2004, doi: 10.1109/TIP.2003.819861 *Disponível em* https://ieeexplore.ieee.org/document/1284395 2004, 47400+ citações segundo o Google Scholar

Image Quality Metrics
SSIM: structural similarity index (full-reference)

this method is that the resulting SSIM index map often exhibits undesirable "blocking" artifacts. In this paper, we use an 11×11 circular-symmetric Gaussian weighting function $\mathbf{w} = \{w_i | i = 1, 2, \cdots, N\}$, with standard deviation of 1.5 samples, normalized to unit sum ($\sum_{i=1}^{N} w_i = 1$). The estimates of local statistics μ_x, σ_x and σ_{xy} are then modified accordingly as

$$\mu_x = \sum_{i=1}^{N} w_i x_i \tag{14}$$

$$\sigma_x = \left(\sum_{i=1}^{N} w_i (x_i - \mu_x)^2 \right)^{\frac{1}{2}} \tag{15}$$

$$\sigma_{xy} = \sum_{i=1}^{N} w_i (x_i - \mu_x)(y_i - \mu_y). \tag{16}$$

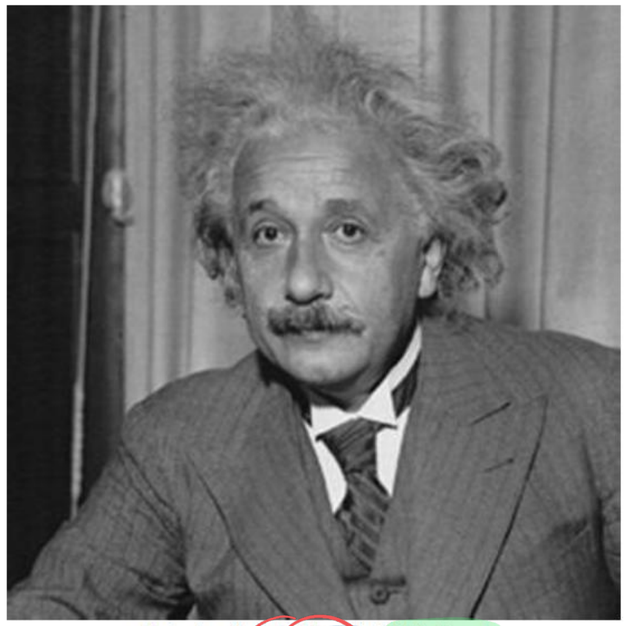
With such a windowing approach, the quality maps exhibit a locally isotropic property. Throughout this paper, the SSIM measure uses the following parameter settings: $K_1 = 0.01$; $K_2 = 0.03$. These values are somewhat arbitrary, but we find that in our current experiments, the performance of the SSIM index algorithm is fairly insensitive to variations of these values.

In practice, one usually requires a single overall quality measure of the entire image. We use a mean SSIM (MSSIM) index to evaluate the overall image quality

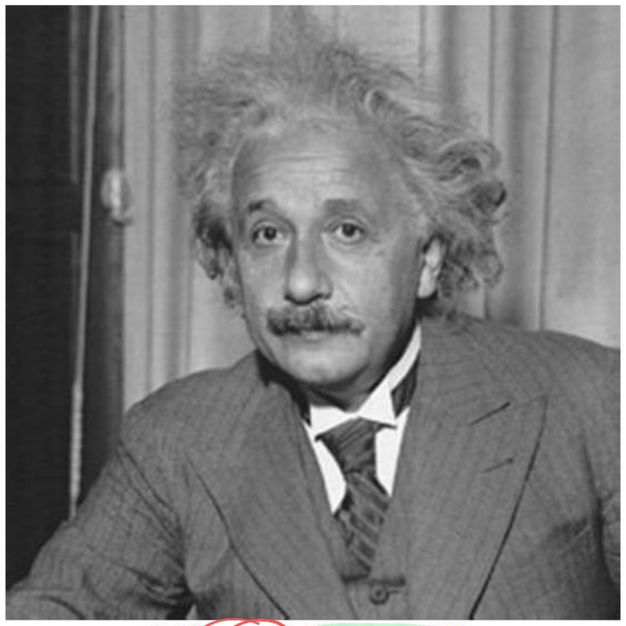
$$\mathrm{MSSIM}(\mathbf{X}, \mathbf{Y}) = \frac{1}{M} \sum_{j=1}^{M} \mathrm{SSIM}(\mathbf{x}_j, \mathbf{y}_j) \tag{17}$$

Zhou Wang, A. C. Bovik, H. R. Sheikh and E. P. Simoncelli, **Image quality assessment: from error visibility to structural similarity**, in *IEEE Transactions on Image Processing*, vol. 13, no. 4, pp. 600-612, April 2004, doi: 10.1109/TIP.2003.819861 *Disponível em* https://ieeexplore.ieee.org/document/1284395 2004, 47400+ citações segundo o Google Scholar

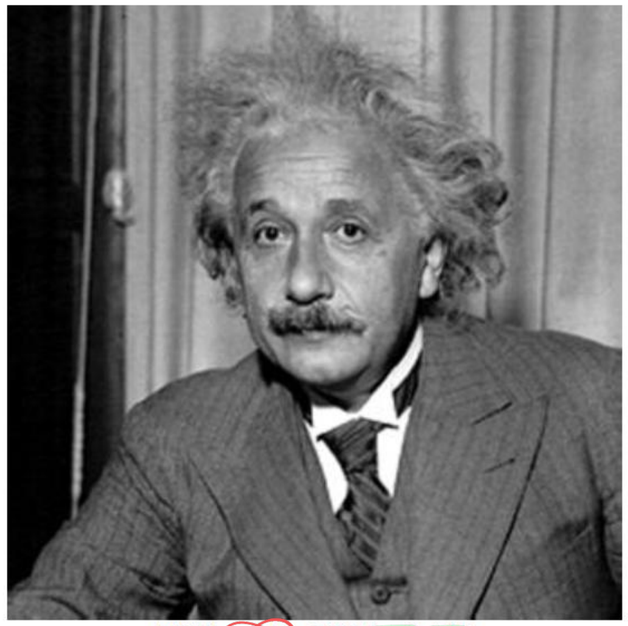
Image Quality Metrics
SSIM: structural similarity index (full-reference)



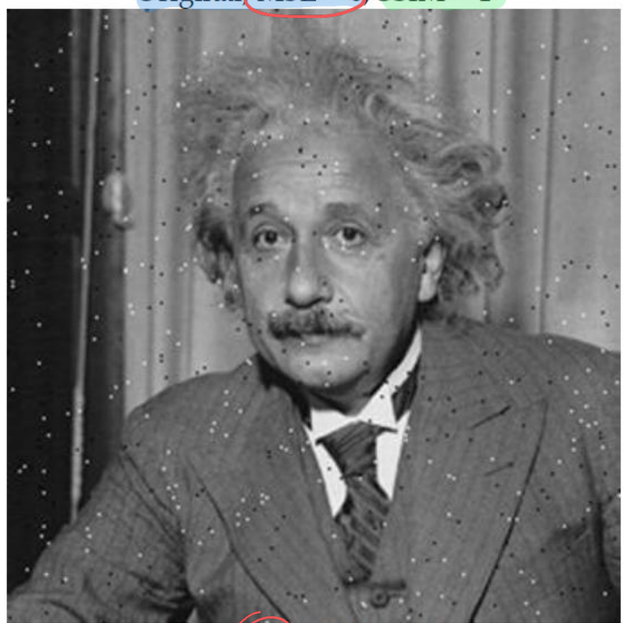
Original, MSE = 0, SSIM = 1



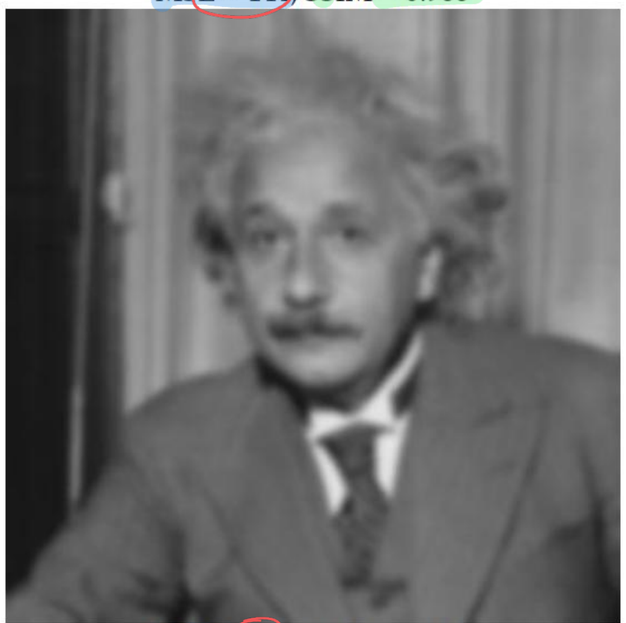
MSE = 144, SSIM = 0.988



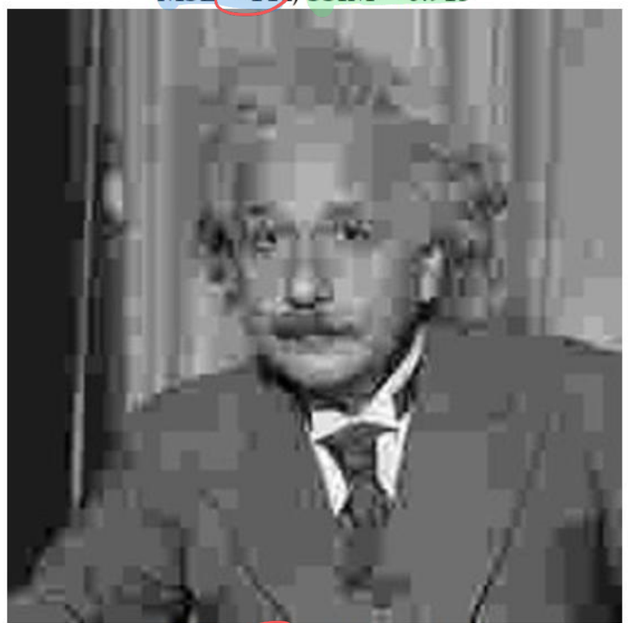
MSE = 144, SSIM = 0.913



MSE = 144, SSIM = 0.840



MSE = 144, SSIM = 0.694



MSE = 142, SSIM = 0.662

The SSIM Index for Image Quality Assessment
Disponível em
https://ece.uwaterloo.ca/~z70wang/research/ssim/
acessado em 17.out.2024

Image Quality Metrics
SSIM: structural similarity index (full-reference)

Zhou Wang, A. C. Bovik, H. R. Sheikh and E. P. Simoncelli, **Image quality assessment: from error visibility to structural similarity**, in *IEEE Transactions on Image Processing*, vol. 13, no. 4, pp. 600-612, April 2004, doi: 10.1109/TIP.2003.819861
Disponível em https://ieeexplore.ieee.org/document/1284395 47400+ citações segundo o Google Scholar

O paper original do SSIM (acima) é bem escrito e inteligível, mas há outras fontes para explorar o método em detalhes. Por exemplo:

- Jim Nilsson and Tomas Akenine-Möller, **Understanding SSIM**, *arXiv*, 2006.13846, eess.IV, 2020. *Disponível em* https://arxiv.org/abs/2006.13846
  80+ citações segundo o Google Scholar

- Z. Wang and A. C. Bovik, **Mean squared error: Love it or leave it? A new look at Signal Fidelity Measures**, in *IEEE Signal Processing Magazine*, vol. 26, no. 1, pp. 98-117, Jan. 2009, doi: 10.1109/MSP.2008.930649. Disponível em https://ieeexplore.ieee.org/abstract/document/4775883
  3490+ citações segundo o Google Scholar

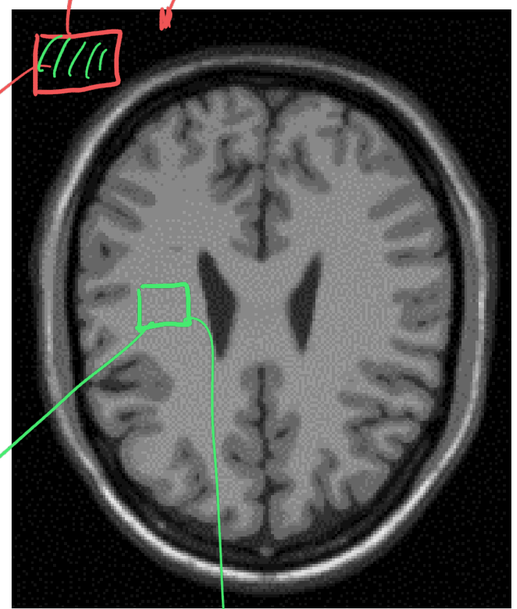
- Alan C. Bovik, The Essential Guide to Image Processing, Academic Press, 2009. 2nd ed, 2009. Capítulo 21, itens 21.3.1 e 21.3.2. *Disponível na EBSCO da UTFPR*: para fazer login, entrar em http://portal.utfpr.edu.br/biblioteca/bibliotec, clicar em 'Bases de Dados' e depois em 'Coleção Acadêmica de E-books (EBSCO)'

- Wikipedia, **Structural similarity** *Disponível em* https://en.wikipedia.org/wiki/Structural_similarity

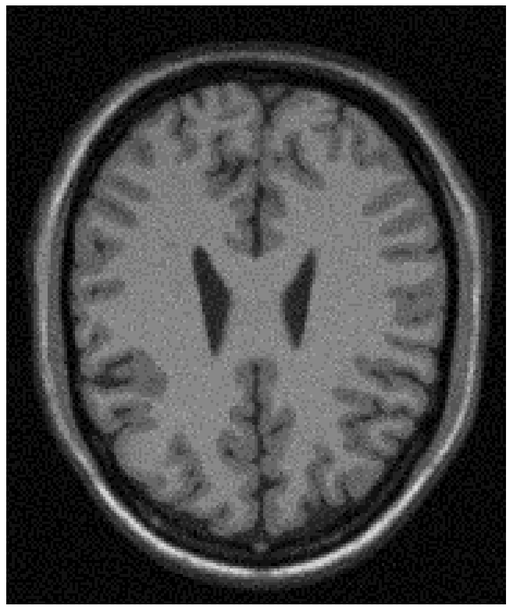
Image Quality Metrics

SNR_L: local signal-to-noise ratio (no-reference)

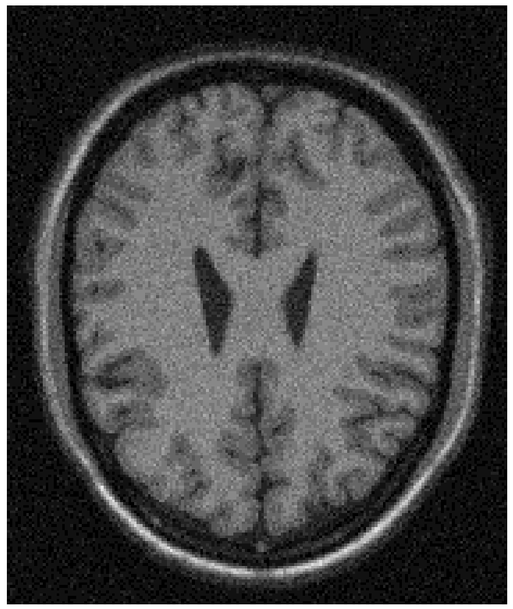
$$SNR_L = \frac{m_s}{\sigma_n}$$



91



SNR_2 35



SNR_3 18

RM

σ

mas sem sinal

aqui só há ruído

pode ter variação do nível de cinza afetando o cálculo do σ do ruído

m_s a média do sinal

SNR_1

Imagens geradas em BrainWeb: Simulated Brain Database, https://brainweb.bic.mni.mcgill.ca/brainweb