IF69D-S11 e OPEET014-OPEL

Processamento Digital de Imagens

Parte 1 - detecção bordas

Parte 2 - Hough transform

Aula 06

Universidade Tecnológica Federal do Paraná - UTFPR - Curitiba
Departamento Acadêmico de Eletrônica - DAELN
Curso de Engenharia Eletrônica
Prof. Humberto R. Gamba e Gustavo B. Borba

29.set.2026

As operações de processamento de imagem
podem ser classificadas em três níveis

Nível baixo: a entrada é uma imagem e a saída é uma imagem para visualização ou para próximas etapas de processamento.
Por exemplo: atenuação de ruído, melhoria de contraste, etc.

Nível médio: extração de atributos.
Por exemplo: bordas, corners, regiões, etc.

Nível alto: interpretação do conteúdo da imagem.
Por exemplo: classificação de imagem, detecção de objetos, etc.

Rafael C. Gonzalez, Richard E. Woods, Steven L. Eddins, Digital image processing, Pearson Prentice Hall, 3rd ed, 2008.

Detecção de bordas

- Bordas são descontinuidades na intensidade dos níveis de cinza.
- Deseja-se que um processo de detecção de bordas apresente na saída uma imagem binária, que indica as bordas da imagem de entrada.

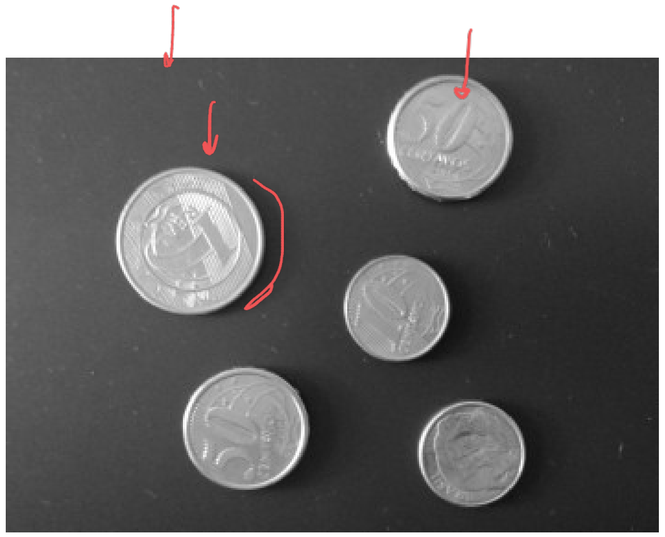
CANNY

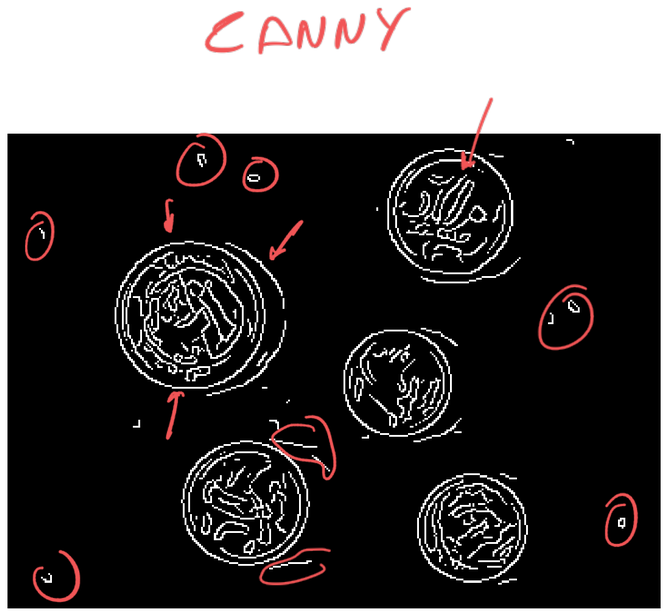


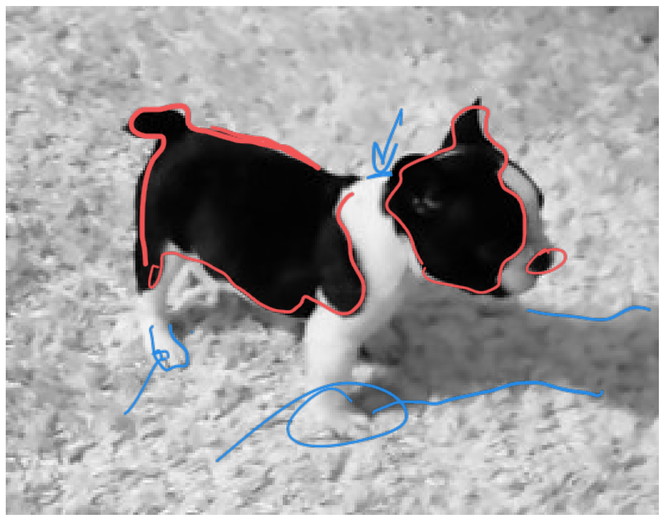


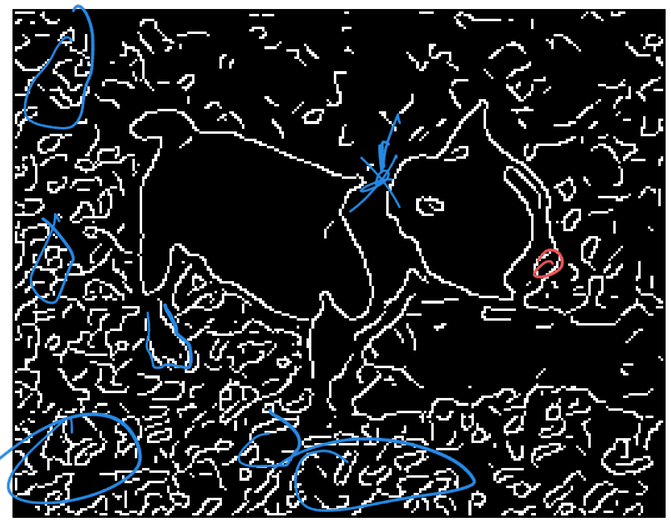
Imagem: https://www2.eecs.berkeley.edu/Research/Projects/CS/vision/grouping/segbench/BSDS300/html/dataset/images/gray/42049.html

Detecção de bordas





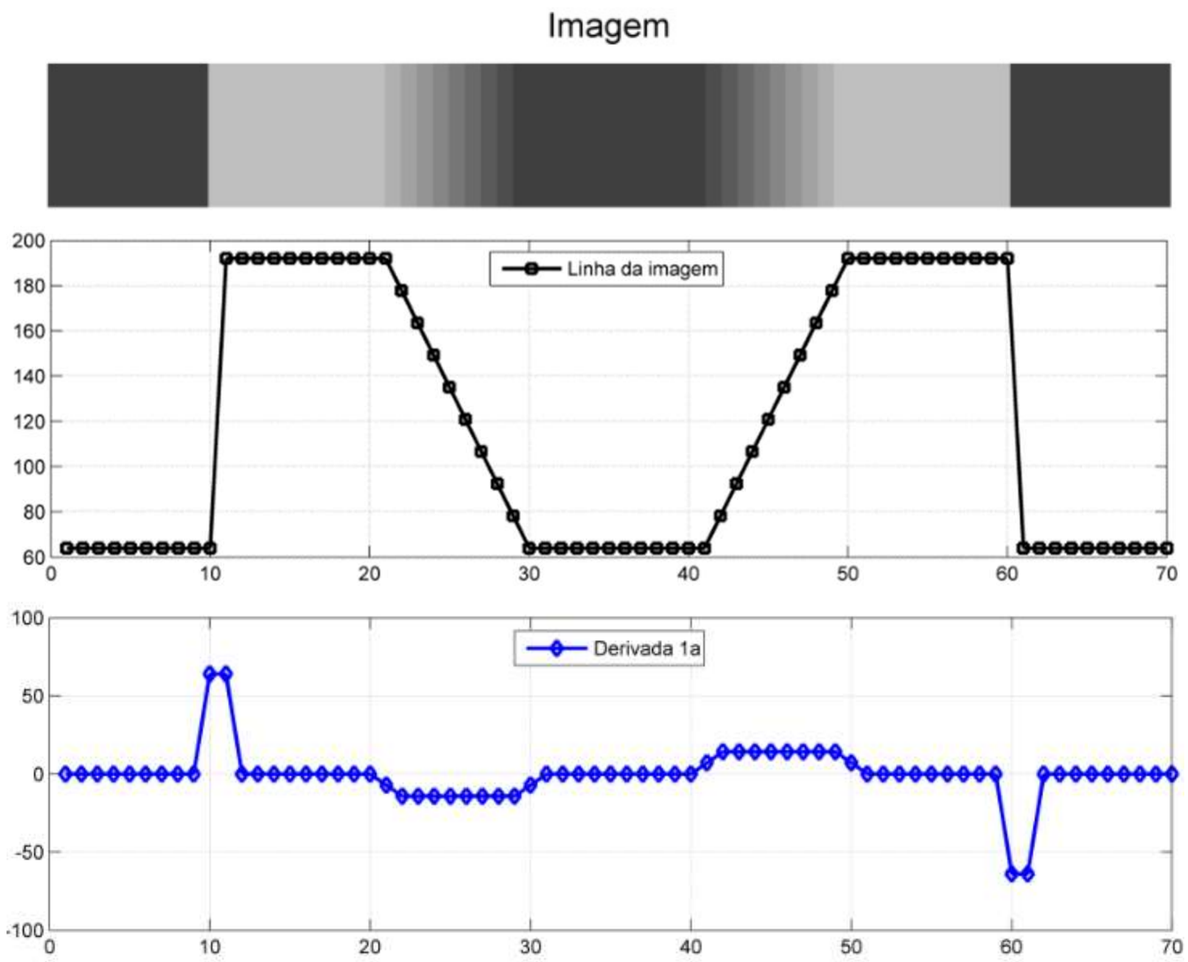




Detecção de bordas por gradiente (derivada primeira)

- A derivada de uma constante (não tem variação) é zero.
- A derivada de um degrau é um impulso.
- A derivada de uma reta (inclinação constante) é uma constante.

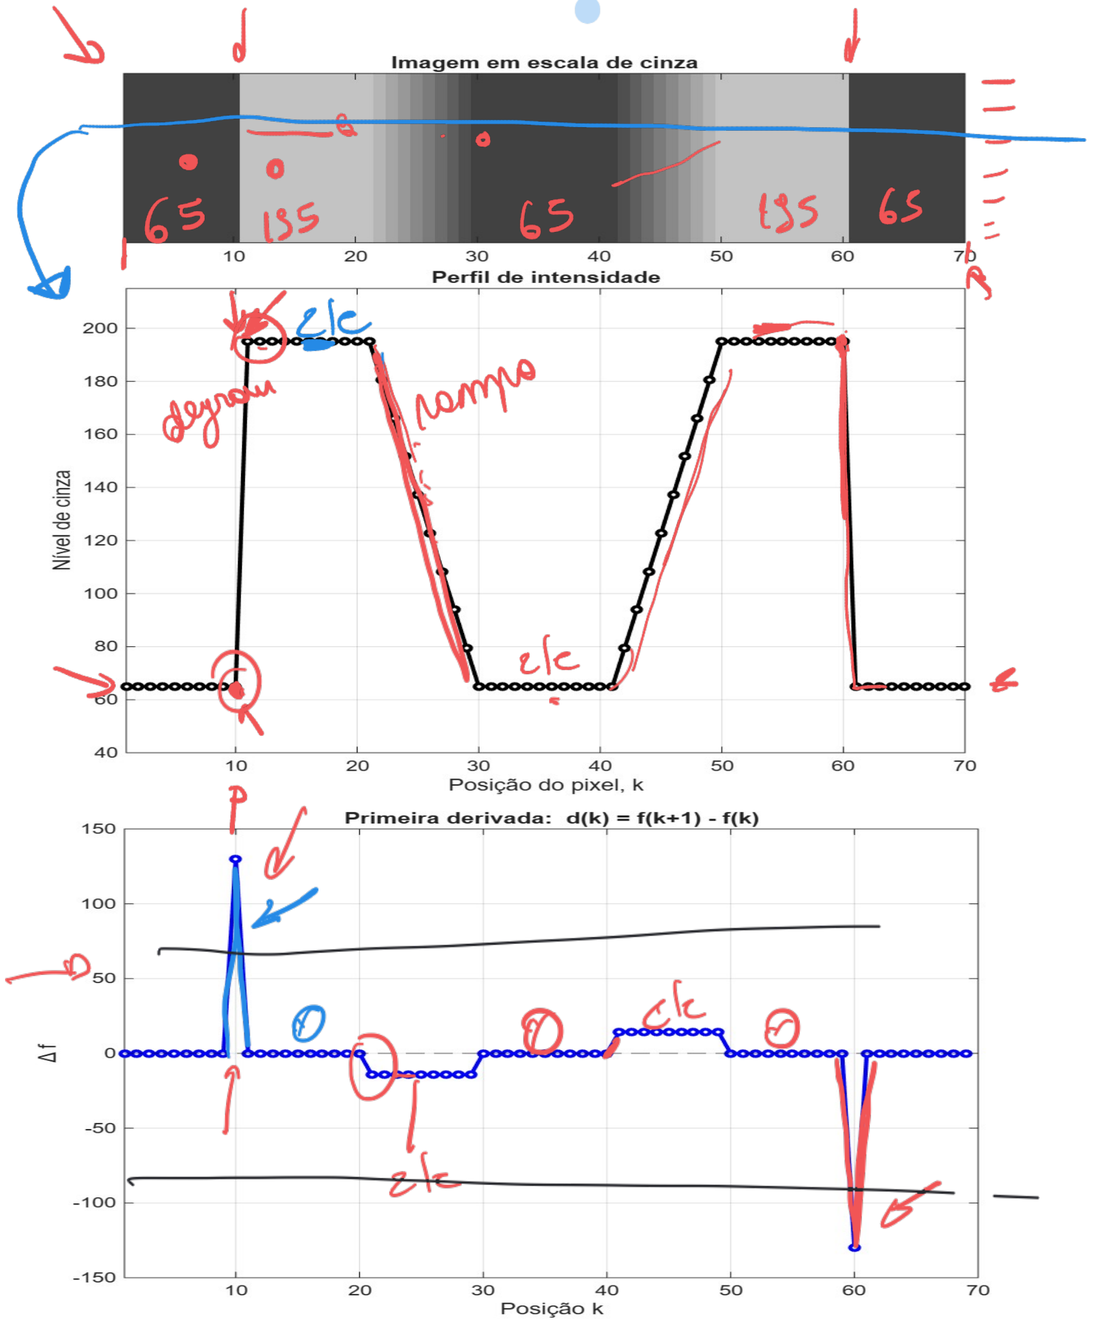
$$\frac{df}{dx} = \lim_{h \to 0} \frac{f(x+h) - f(x-h)}{2h} = \frac{f(x+1) - f(x-1)}{2}$$



descartar esse slide

```
row = img(1,1:ncol);
% Derivada de
% primeira ordem
% segundo definição
for k=2:ncol-1
 d(k)=row(k+1)-row(k-1);
end
d=d/2; % Derivada 1a
```

Detecção de bordas por gradiente: diferença entre pixels adjacentes



Aproximação da primeira derivada pela diferença entre pixels vizinhos:

$$d(x) = f(x+1) - f(x)$$

$$f(10) = 65 \qquad f(10+1) = 195$$

$$d(x) = f(11) - f(10) = 195 - 65 = 130$$

Posição da diferença: geometricamente, a variação está associada ao ponto entre os dois pixels x e $x+1$

$$x + \frac{1}{2}$$

$$f(10) \qquad d(x) \qquad f(10+1)$$

$$x = 10{,}5$$

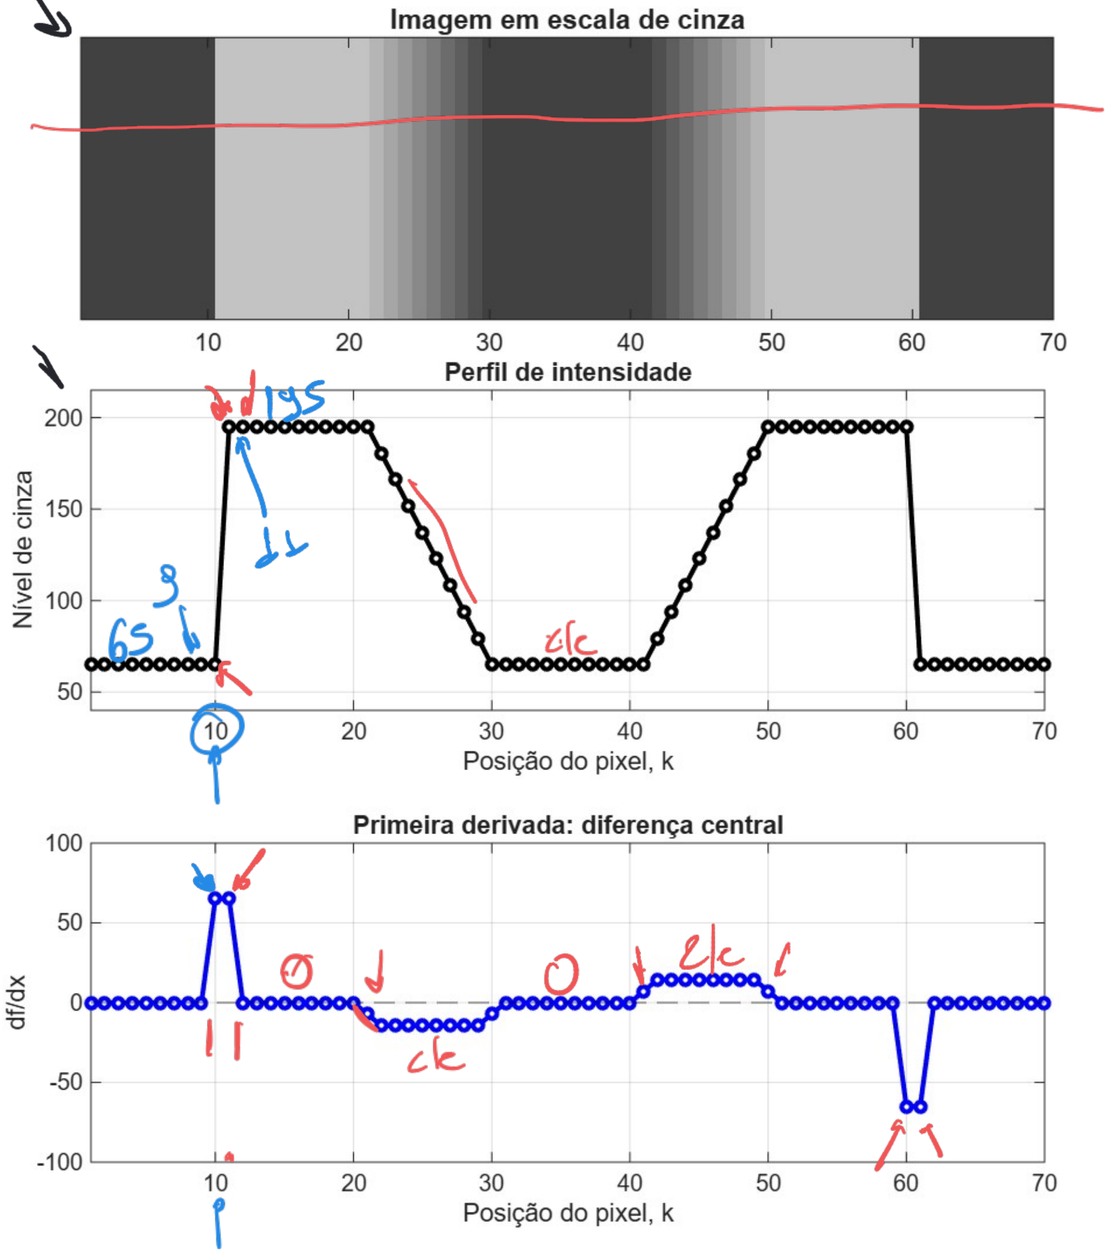
Interpretação: Quanto maior a variação de intensidade entre pixels vizinhos, maior a resposta da derivada e maior a evidência de uma borda.

```
row = img ( 1 , 1 : ncol);
for k = 1 : ncol - 1
    d(k) = row(k+1) - row(k);
end
```

No gráfico, por conveção, representamos $d(x)$ na posição x. Geométricamente representaríamos em $x + \frac{1}{2}$.

Detecção de bordas por gradiente: diferença central

primeiro derivado



$$d(x) = \frac{f(x+1) - f(x-1)}{2}$$

O valor calculado é associado ao pixel central x.

No degrau entre os pixels 10 e 11, a diferença central produz resposta nos dois pixels adjacentes a transição.

No pixel 10:

$$d(10) = \frac{f(11) - f(9)}{2} = \frac{195 - 65}{2} = 65$$

No pixel 11:

$$d(11) = \frac{f(12) - f(10)}{2} = \frac{195 - 65}{2} = 65$$

O degrau que anteriormente produzia um pico de 130 entre os pixels 10 e 11 passa a produzir **dois valores de 65, nas posições 10 e 11**.

Consequência da máscara da diferença central:

$$\frac{1}{2}\begin{bmatrix} -1 & 0 & 1 \end{bmatrix}$$

$x-1 \quad x \quad x+1$

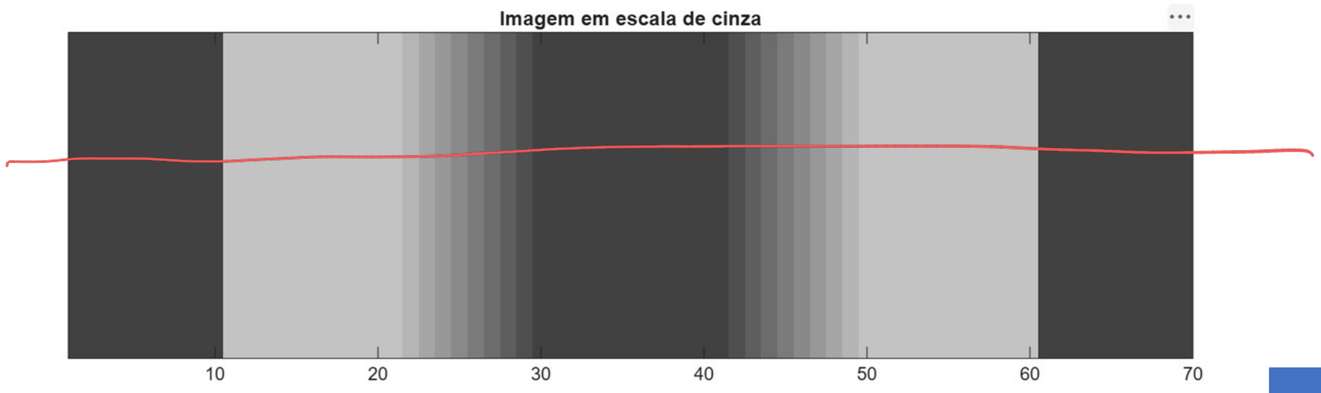
```
row = img(1,1:ncol);
for k=2:ncol-1
 d(k)=(row(k+1)-row(k-1))/2;
end
```

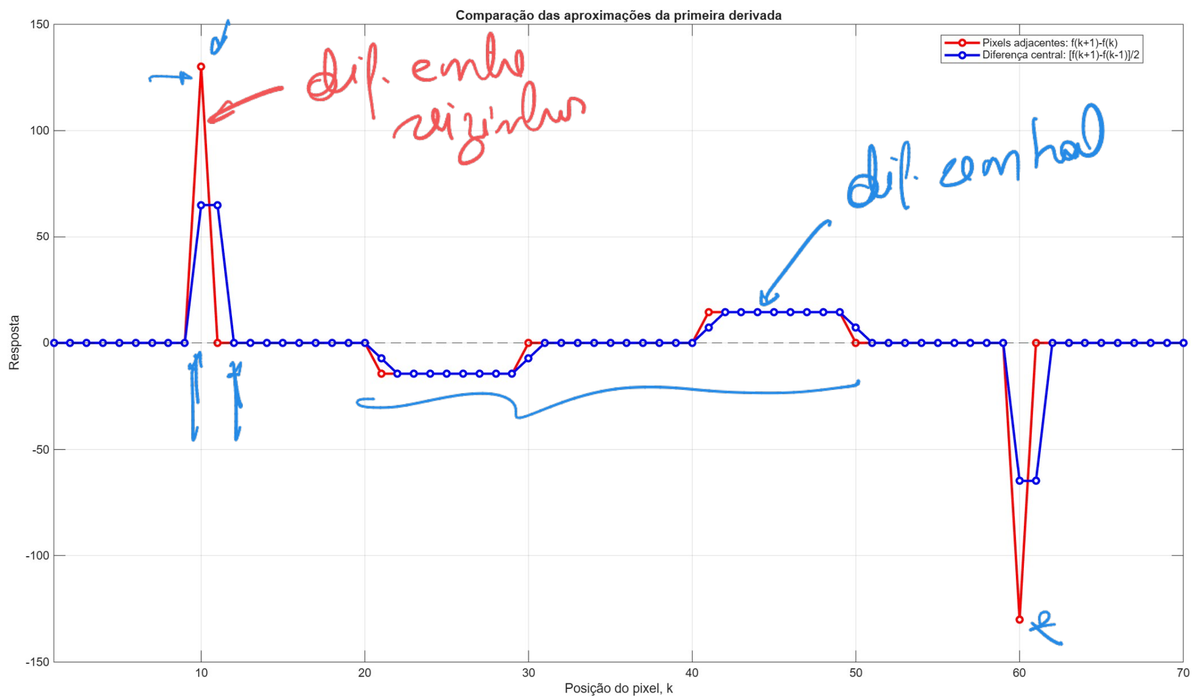
$$\Delta x = (x+1) - (x-1) = 2$$

$$d(x) = \frac{f(x+1) - f(x-1)}{\Delta x \leftarrow 2}$$

-1	0	1

Detecção de bordas por gradiente: comparação entre diferença entre vizinhos e diferença central

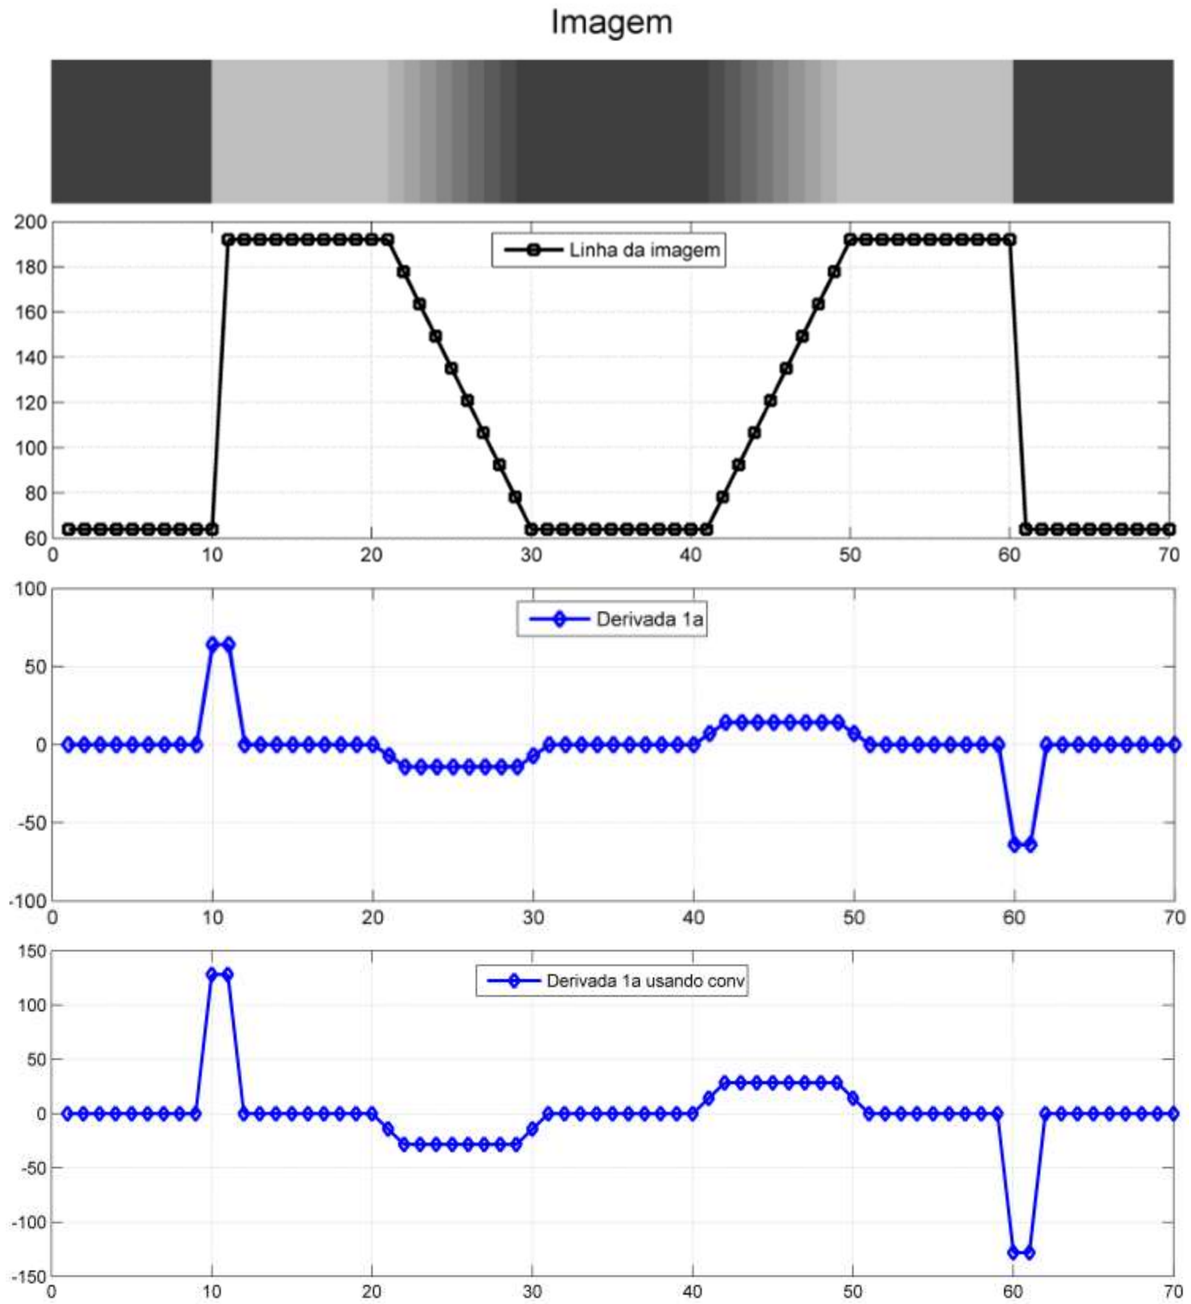




Pixels adjacentes	Diferença central
$f(x+1)-f(x)$	$\frac{f(x+1)-f(x-1)}{2}$
compara 2 pixels adjacentes	compara $x-1$ e $x+1$
resposta associada à transição entre x e $x+1$	resposta associada a x
degrau: 1 pico de 130	degrau: 2 valores de 65

As duas operações podem ser implementadas por máscaras e, consequentemente, por convolução.

Detecção de bordas por gradiente (derivada primeira usando convolução)

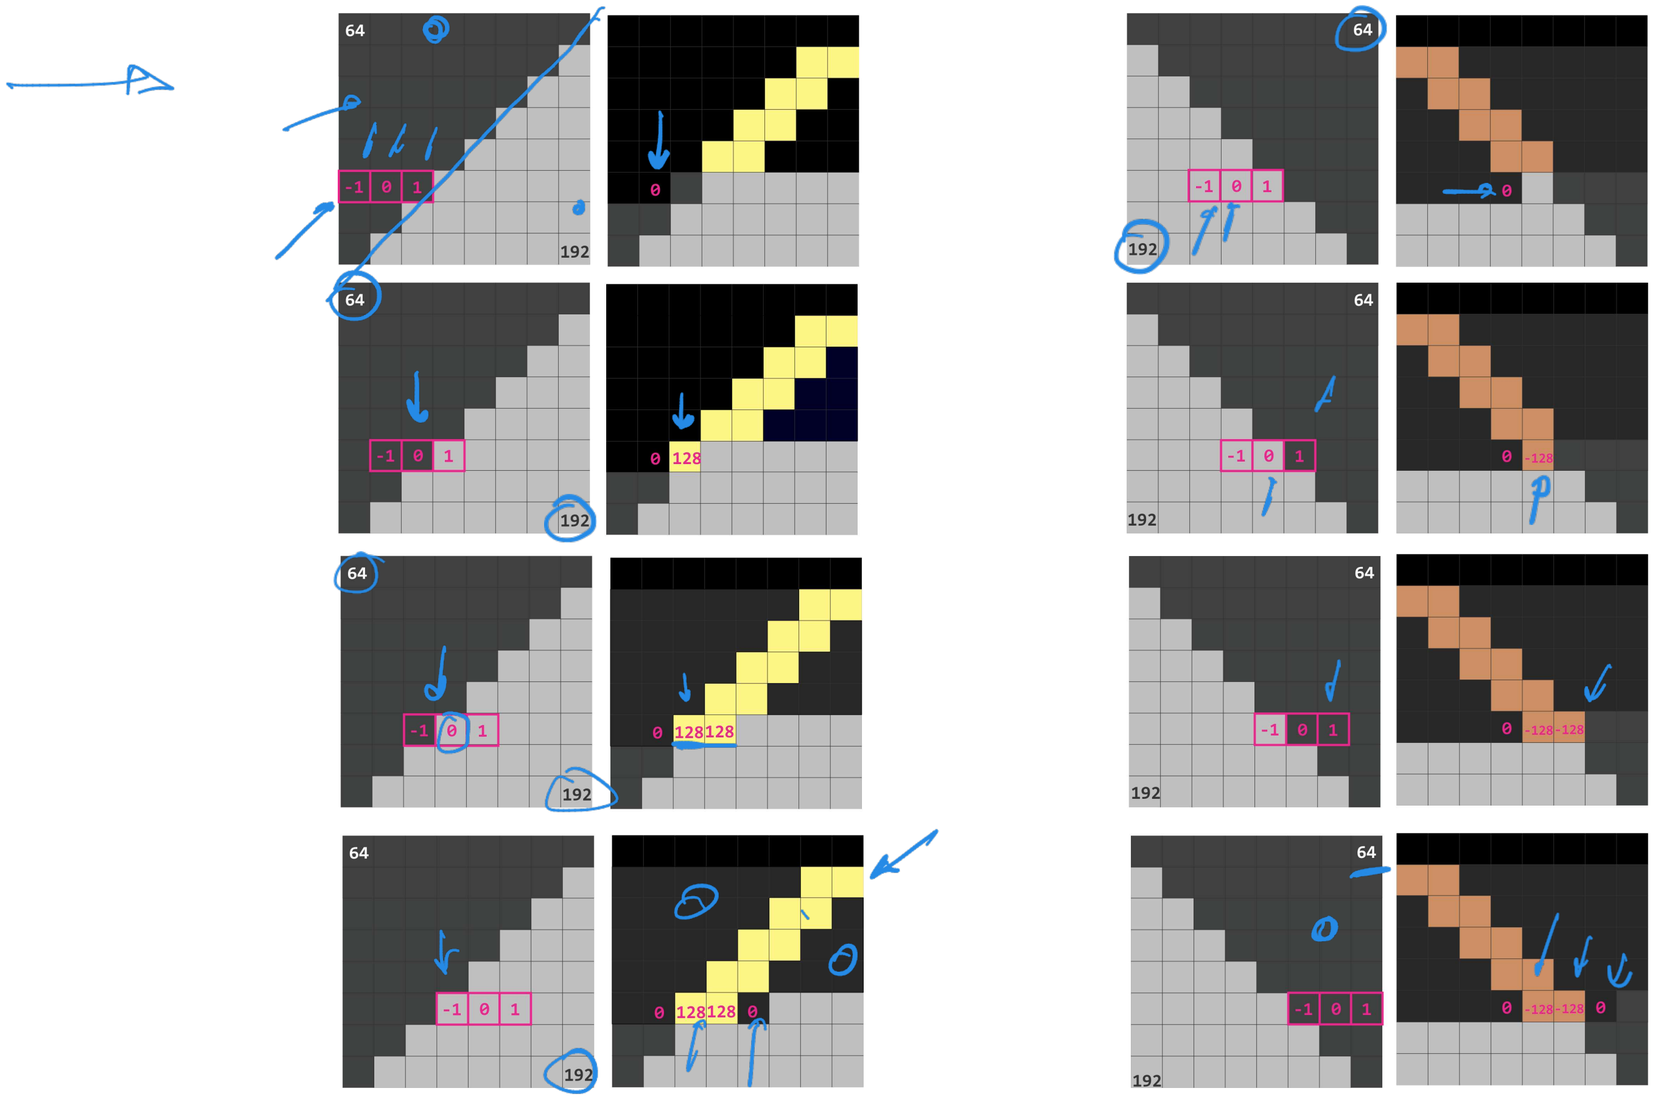


descartar esse slide

```
row = img(1,1:ncol);
% Derivada de
% primeira ordem
% segundo definição
for k=2:ncol-1
 d(k)=row(k+1)-row(k-1);
end
d=d/2; % Derivada 1a

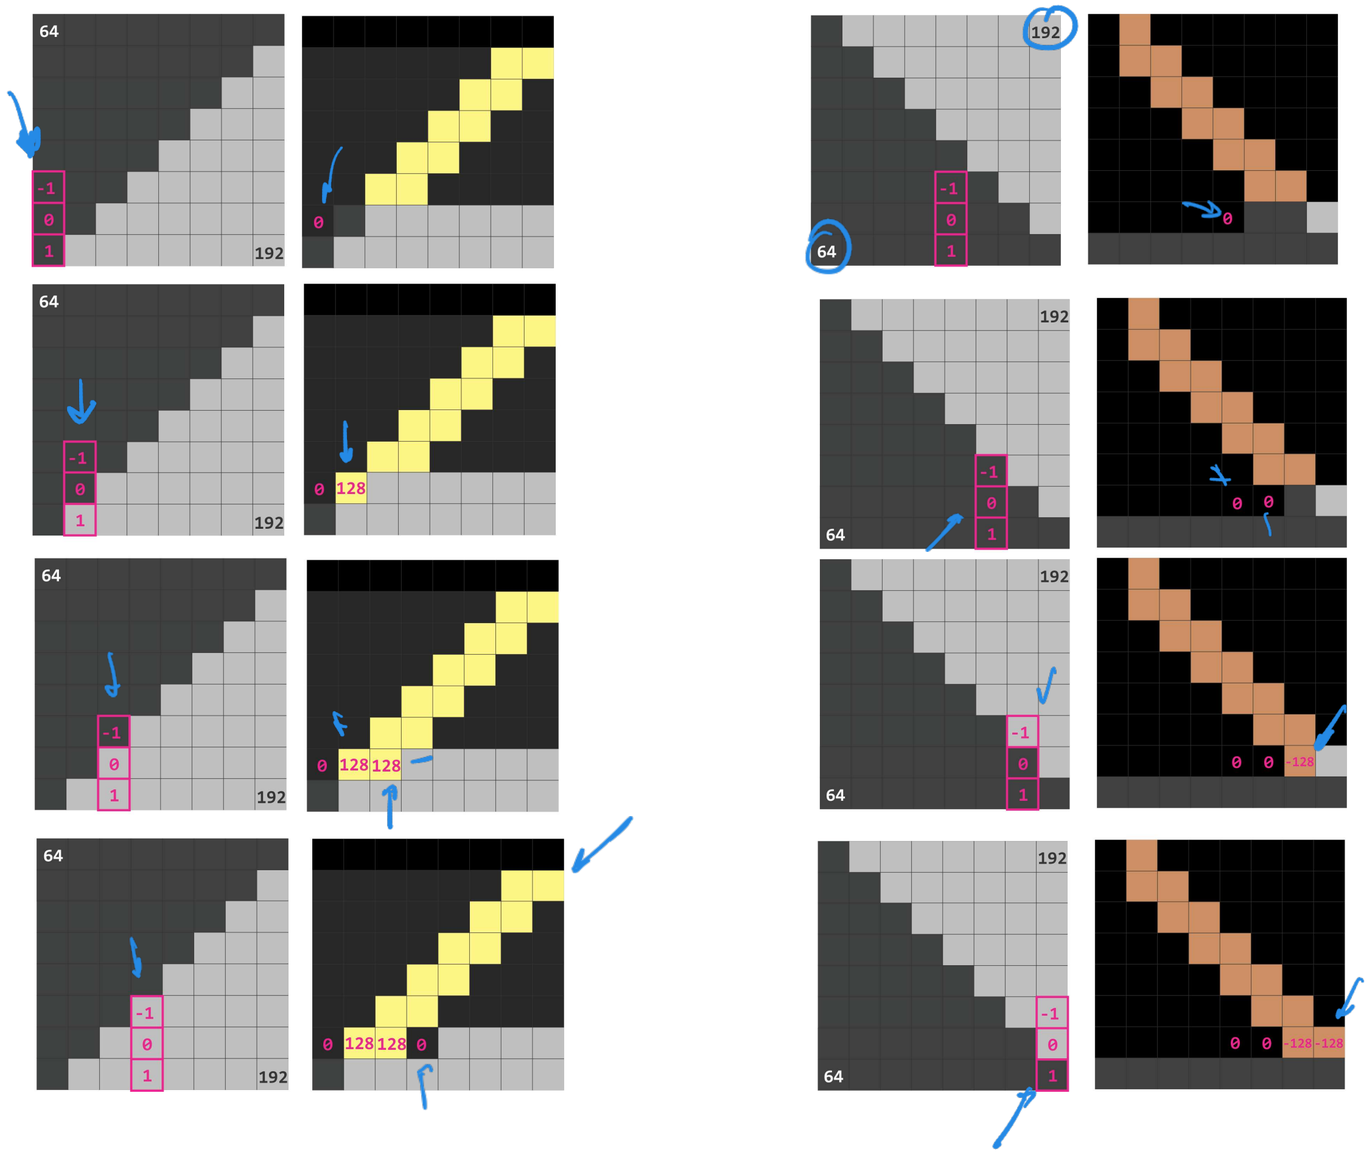
% Máscara para derivada 1a
% por convolução para
% reproduzir f(x+1)-f(x-1).
% Fazer conv com [1 0 -1] e
% não com [-1 0 1] porque a
% convolução espelha a
% máscara em x e y.
h = [1 0 -1];
d = conv(row,h,'valid');
```

Detecção de bordas por gradiente (derivada primeira) com a convolução nas duas direções (máscara horizontal e máscara vertical)

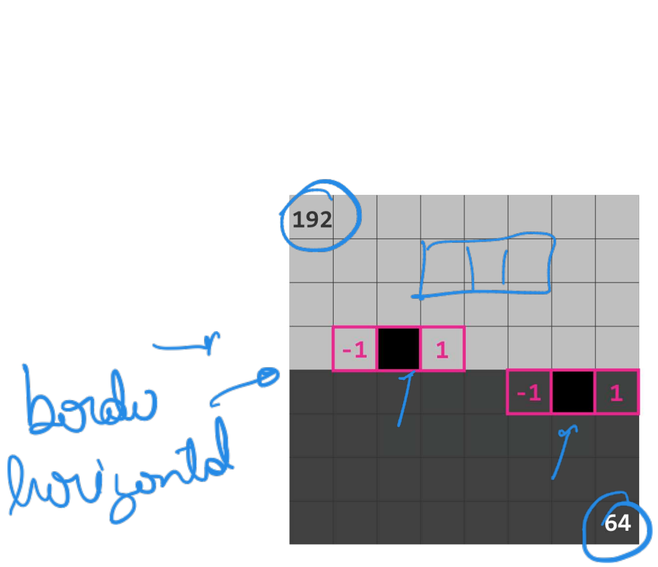


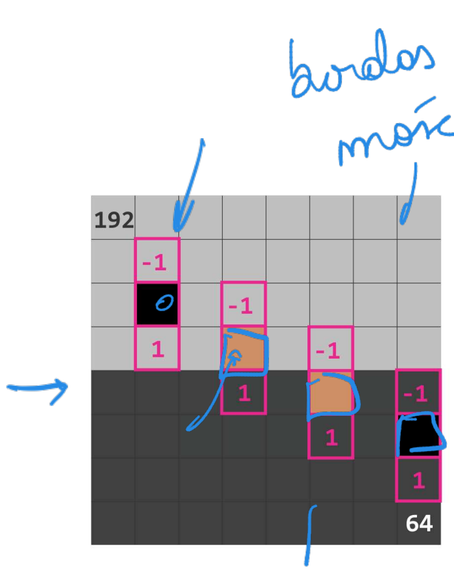


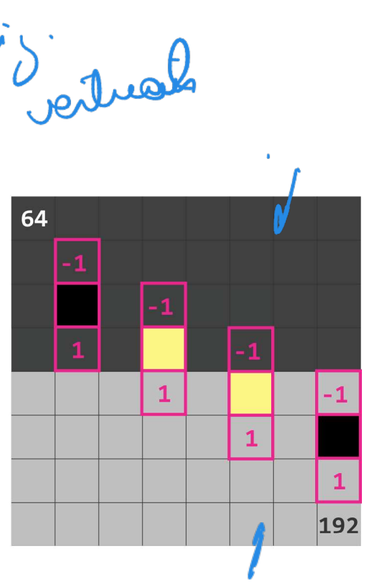
Detecção de bordas por gradiente (derivada primeira) com a convolução nas duas direções (máscara horizontal e máscara vertical)

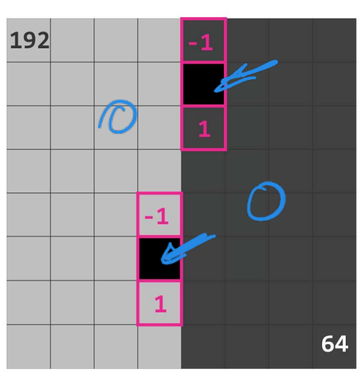


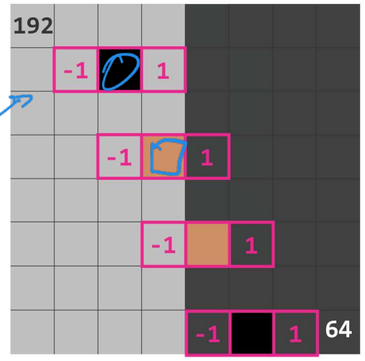
Detecção de bordas por gradiente (derivada primeira) com a convolução nas duas direções (máscara horizontal e máscara vertical)

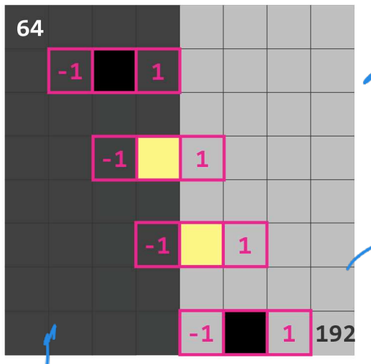












Detecção de bordas por gradiente (derivada primeira)
Máscaras mais utilizadas:

Respondem com mais intensidade às variações ao longo da direção horizontal. *Variações ao longo da direção horizontal são bordas verticais.*

-1	0	1
-1	0	1
-1	0	1

Prewitt vertical
(para bordas verticais)

-1	-1	-1
0	0	0
1	1	1

Prewitt horizontal
(para bordas horizontais)

Respondem com mais intensidade às variações ao longo da direção vertical. *Variações ao longo da direção vertical são bordas horizontais.*

-1	0	1
-2	0	2
-1	0	1

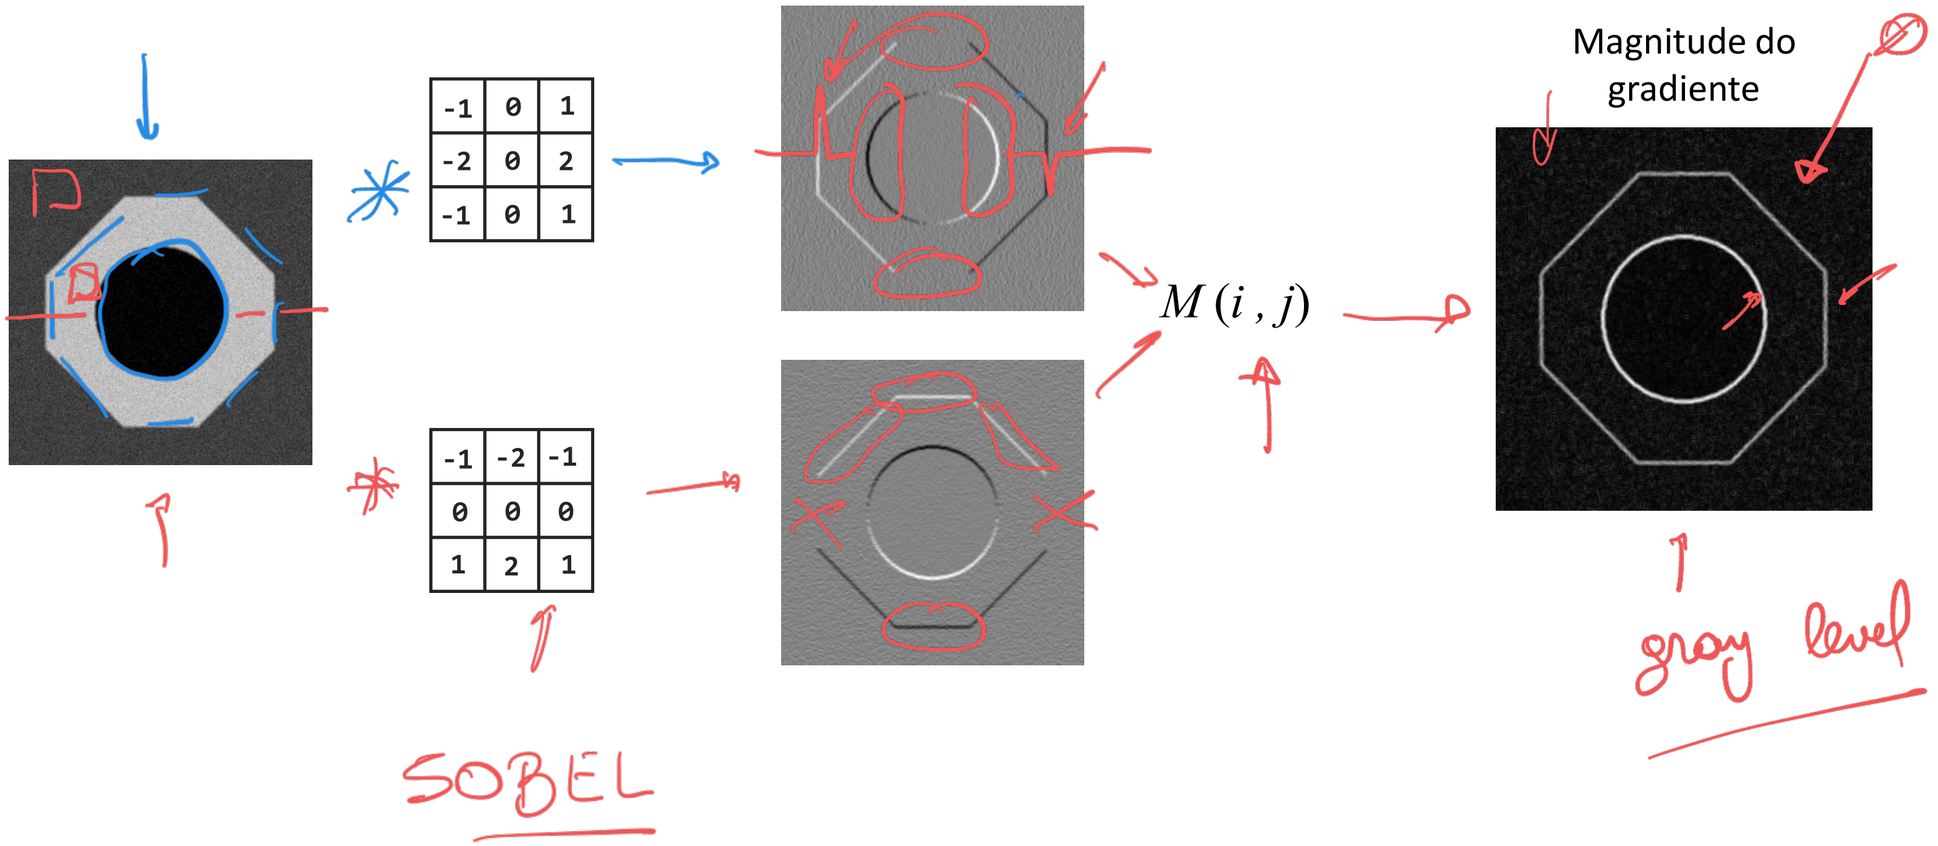
Sobel Vertical
(para bordas verticais)

-1	-2	-1
0	0	0
1	2	1

Sobel horizontal
(para bordas horizontais)

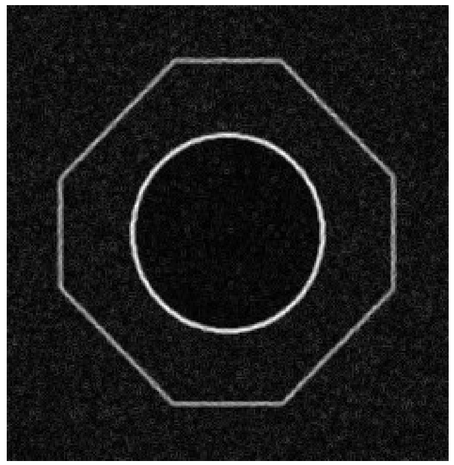
Detecção de bordas por gradiente (derivada primeira)
Combinando as saídas das máscaras nas duas direções:

$$M(i,j) = \sqrt{G_v(i,j)^2 + G_h(i,j)^2}$$



A saída esperada de um detector de bordas é uma imagem binária

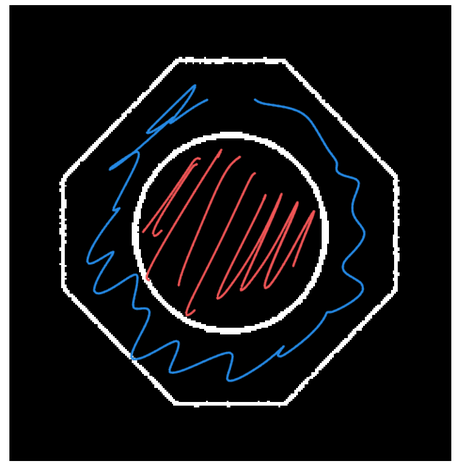
Magnitude do gradiente



gray level image

→ limiarização →

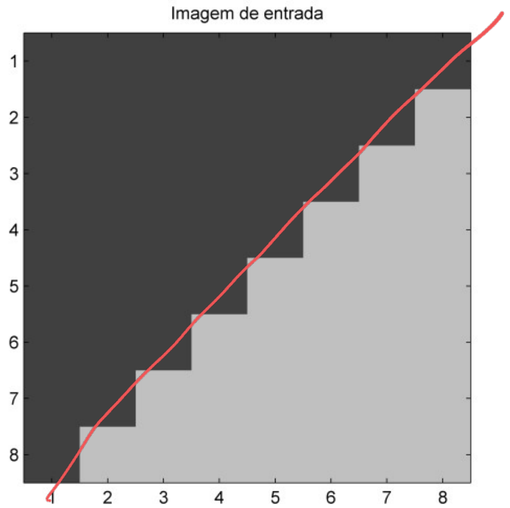
Magnitude do gradiente BW



BW

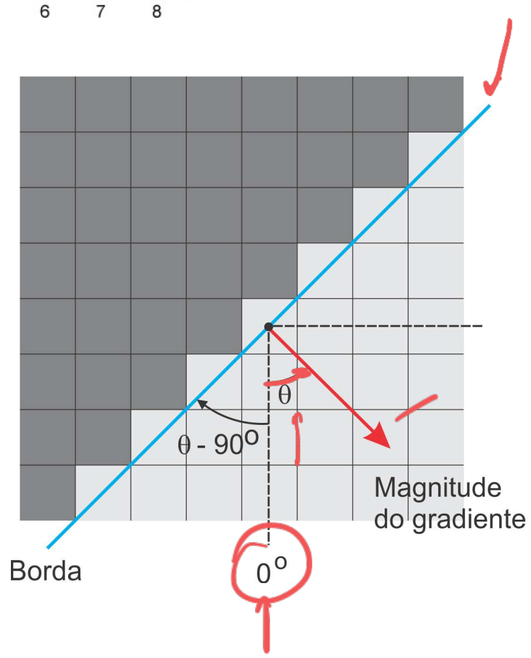
Detecção de bordas por gradiente (derivada primeira)

Direção (ângulo) do vetor magnitude do gradiente e da borda:



$$\theta(i,j) = tan^{-1}\left(\frac{G_h(i,j)}{G_v(i,j)}\right)$$

NaN	NaN	NaN	NaN	NaN	NaN	45.00	71.57
NaN	NaN	NaN	NaN	NaN	45.00	45.00	63.43
NaN	NaN	NaN	NaN	45.00	45.00	45.00	45.00
NaN	NaN	NaN	45.00	45.00	45.00	45.00	NaN
NaN	NaN	45.00	45.00	45.00	45.00	NaN	NaN
NaN	45.00	45.00	45.00	45.00	NaN	NaN	NaN
45.00	45.00	45.00	45.00	NaN	NaN	NaN	NaN
18.43	26.57	45.00	NaN	NaN	NaN	NaN	NaN



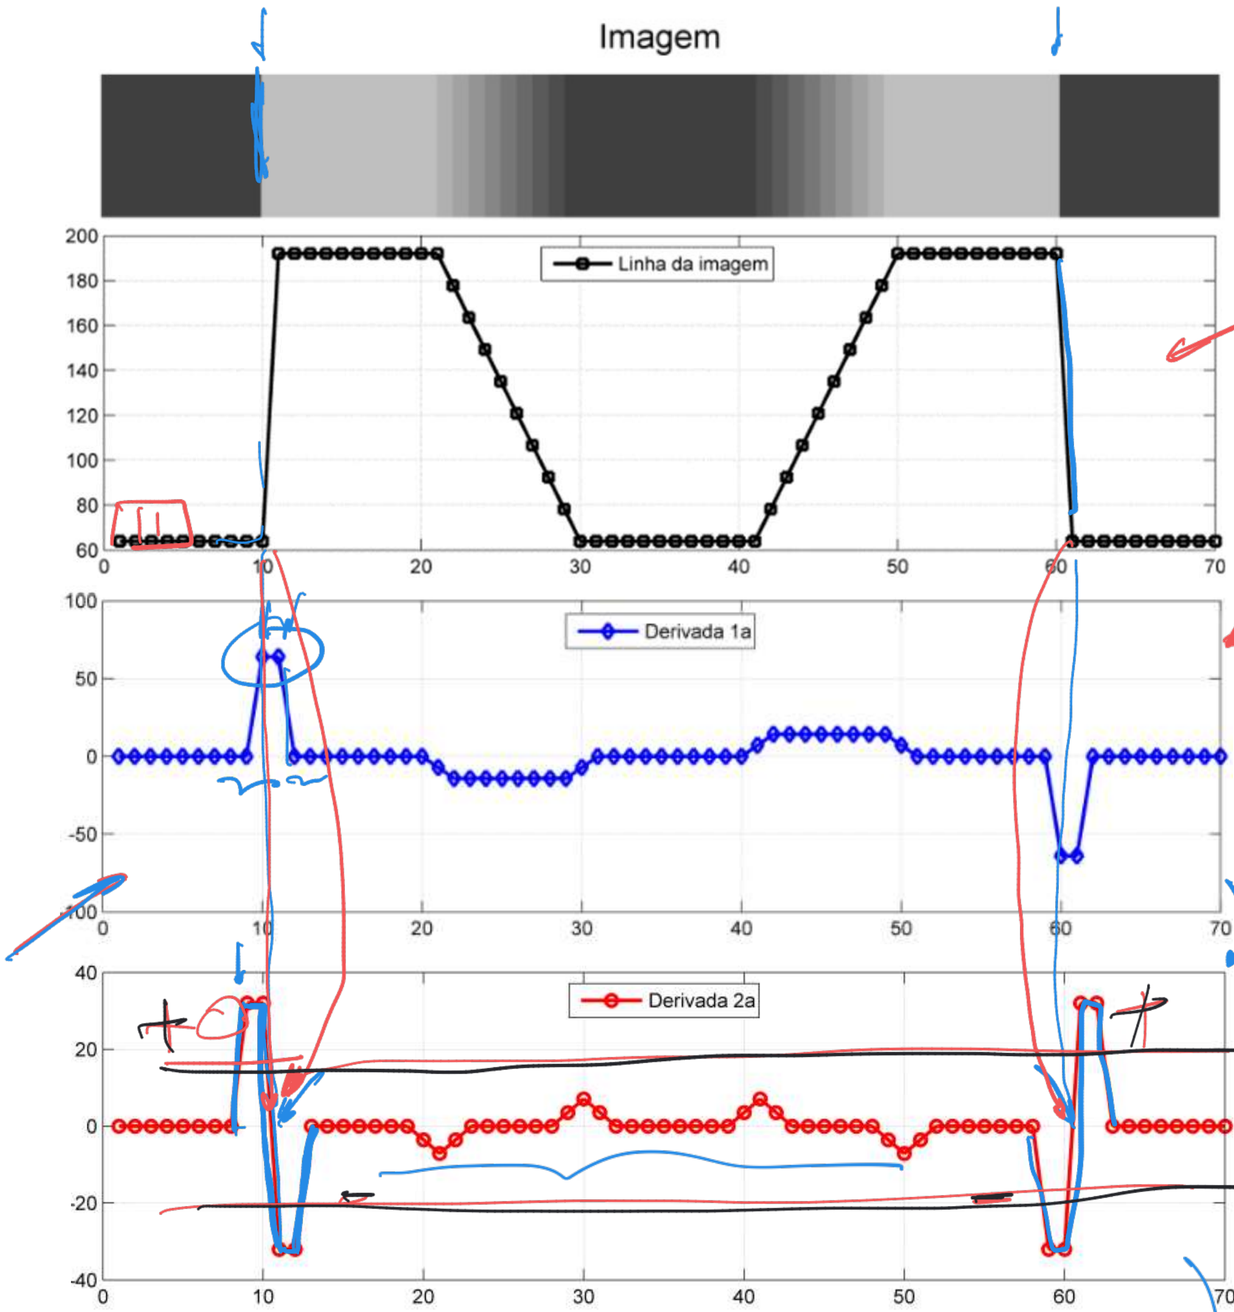
1. A referência é o eixo vertical (0°)
2. O ângulo obtido para a magnitude do gradiente é θ = 45°
3. A borda é ortogonal à magnitude do gradiente
4. O ângulo da borda é dado por θ - 90° = 45° - 90° = -45°

o par ou das máscaras de Sobel

Figura adaptada de Rafael C. Gonzalez, Richard E. Woods, Steven L. Eddins, Digital image processing, Pearson Prentice Hall, 3rd ed, 2008, Figure 10.12.

Detecção de bordas por derivada segunda

- A derivada de uma constante (não tem variação) é zero.
- A derivada de um degrau é um impulso.
- A derivada de uma reta (inclinação constante) é uma constante.




```
row = img(1,1:ncol);
% Derivada de
% primeira ordem
for k=2:ncol-1
 d(k)=row(k+1)-row(k-1);
end
d=d/2; % Derivada 1a

% Derivada de
% segunda ordem
for k = 2 : ncol-1
 dd(k)=d(k+1)-d(k-1);
end
dd=dd/2; % Derivada 2a
```

Detecção de bordas por derivada segunda

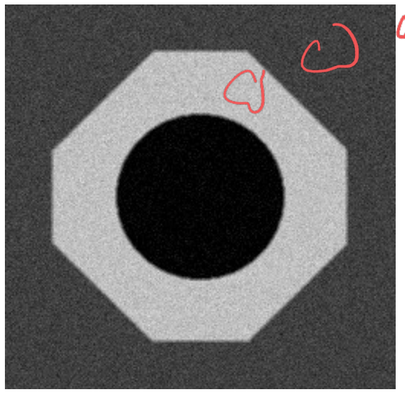
Operador derivada segunda de uma imagem: *Laplaciano*

verifico se tem potencial de borda

$|L(P_1) - L(P_2)| > T$

$L(P_1) \cdot L(P_2) < 0$

deve passar por zero



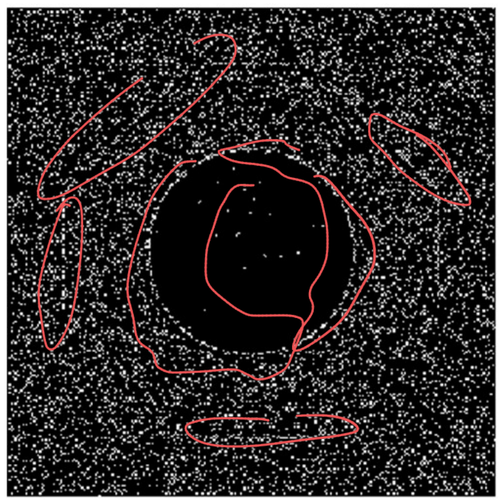
ruído

$*$

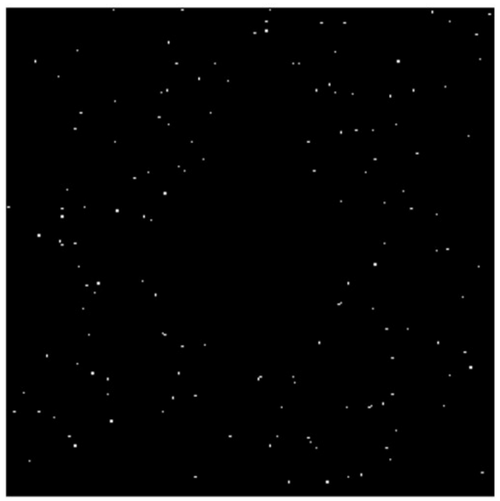
0	1	0
1	-4	1
0	1	0

ZERO-CROSSING DETECTION

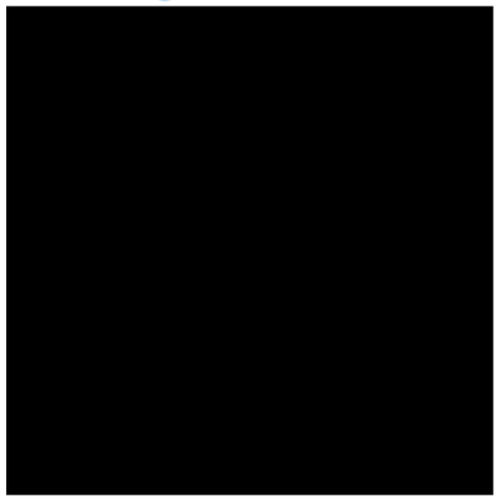
Limiar baixo na detecção de passagem por zero



Limiar médio na detecção de passagem por zero



Limiar alto na detecção de passagem por zero

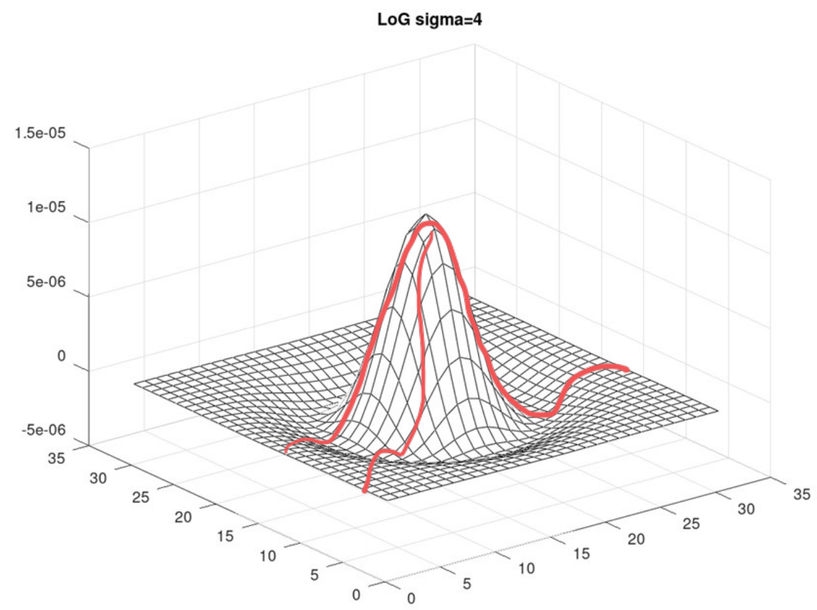


Detecção de bordas por derivada segunda
Laplaciano do Gaussiano (LoG)

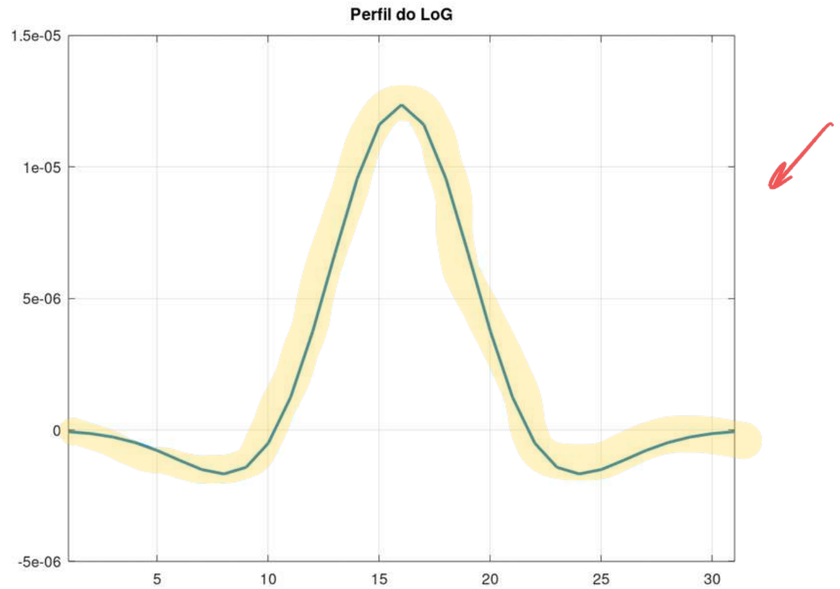
- O *Laplaciano* (derivada segunda 'pura') é muito sensível ao ruído.
- Utiliza-se então a função ***Laplaciano do Gaussino*** **(LoG)**, que combina a derivada segunda com uma suavização.
- O **LoG** pode ser entendido como um Gaussiano (passa-baixas) associado a um Laplaciano: realiza uma suavização e a derivada segunda.

```
% Gera um LoG de sigma=4 em uma janela 31x31
logf = fspecial('log', [31 31], 4);
p = logf(16,:); %linha central
```

```
%Display
figure
mesh(-logf, 'EdgeColor', 'black')
title('LoG sigma=4')
```




```
%Display
figure
plot(1:31,-p,'LineWidth',2)
xlim([1 31])
grid
title('Perfil do LoG')
```



Detecção de bordas por derivada segunda
Difference of Gaussians (DoG)

- A função ***Difference of Gaussians*** **(DoG)** aproxima-se muito bem a uma LoG

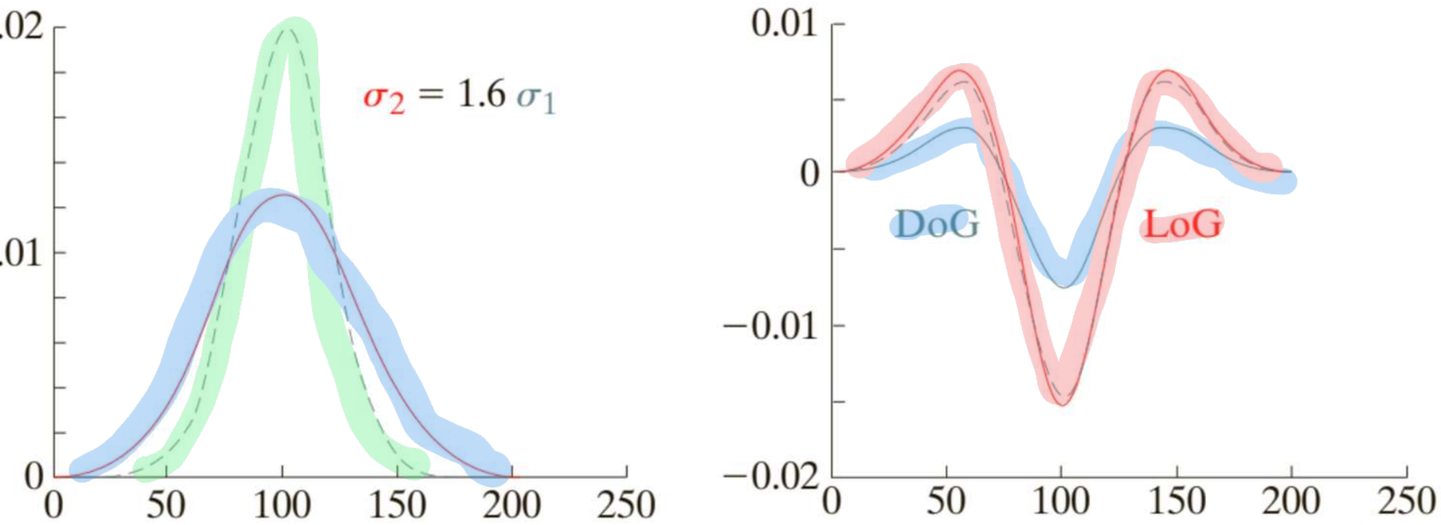
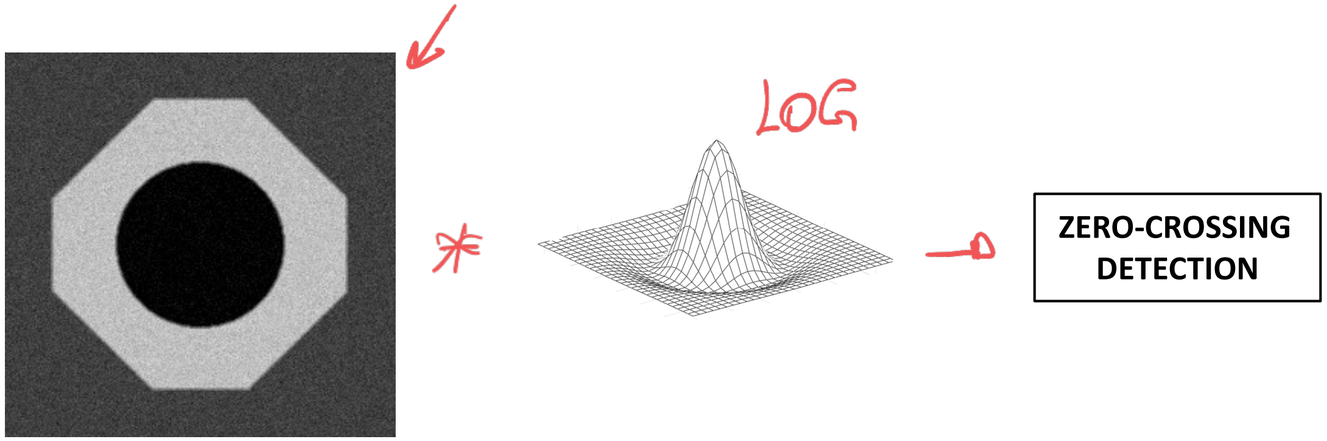


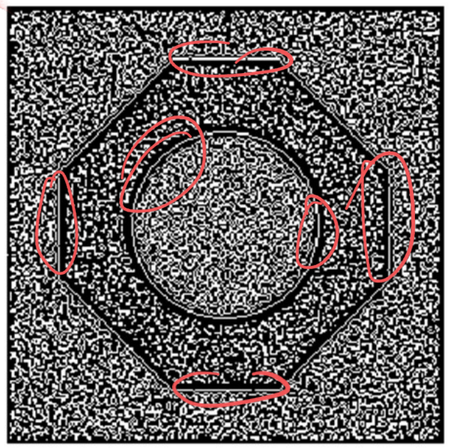
Figure 5.15 LEFT: Two Gaussians whose ratio of standard deviations is 1.6. RIGHT: The difference of Gaussians (solid blue) and 1D Laplacian of Gaussian (solid red). The scaled DoG (dashed blue) approximates the LoG.

Stan Birchfield, Image Processing and Analysis, Cengage Learning, 2018, Figure 5.15.

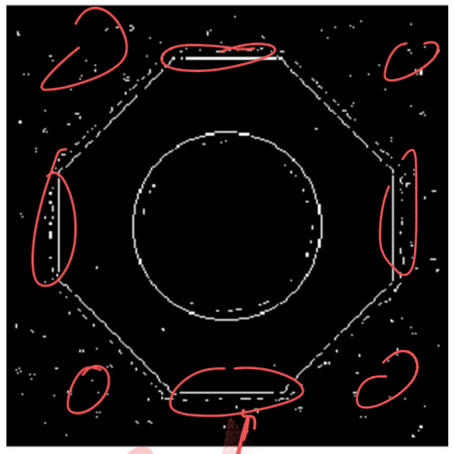
Detecção de bordas por derivada segunda
Laplaciano do Gaussiano (LoG)



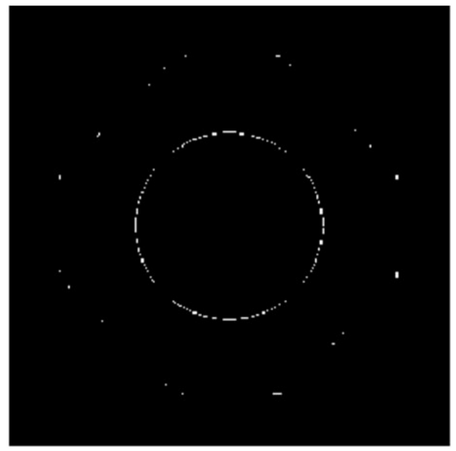
Limiar fixo para detecção de passagem por zero. **Sigma = 1**



Limiar fixo para detecção de passagem por zero. **Sigma = 2**

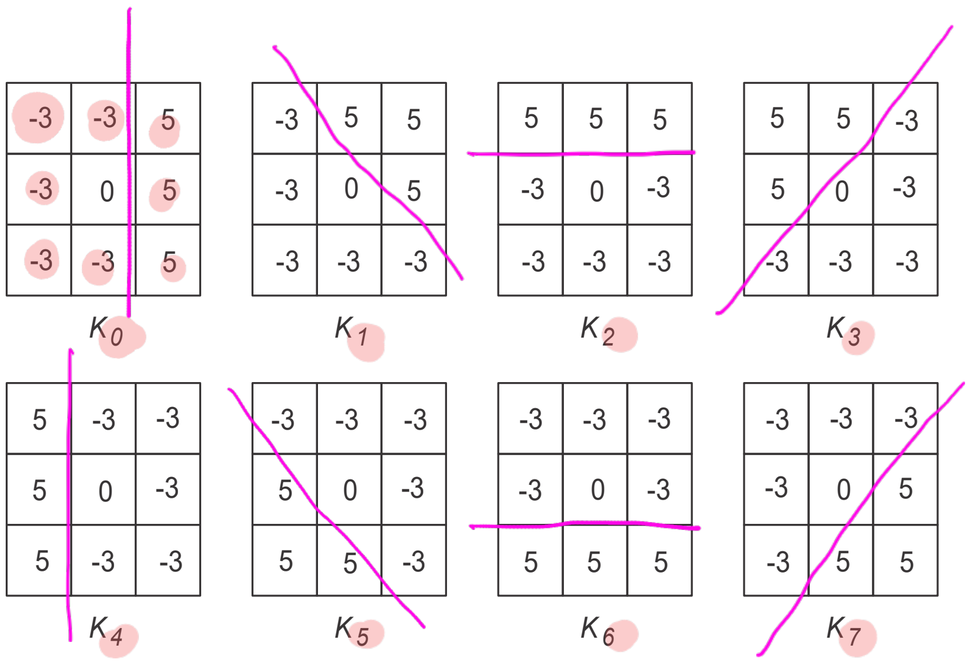


Limiar fixo para detecção de passagem por zero. **Sigma = 3**



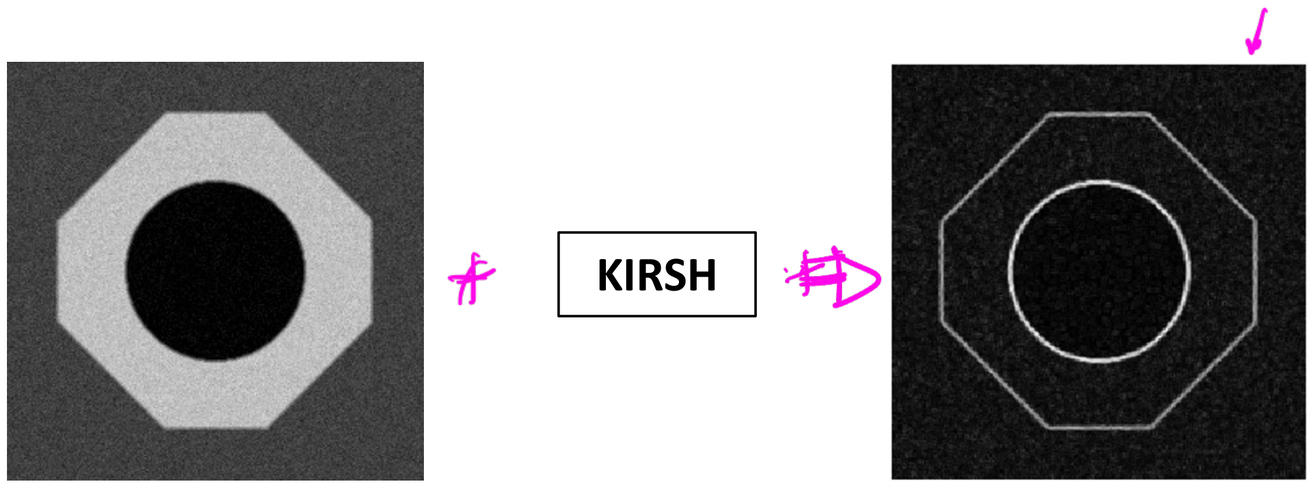
Detecção de bordas por compass operator

Método Kirsh



- A saída do detector de bordas de Kirsh é o máximo das saídas das oito máscaras.
- A orientação é a da própria máscara que forneceu o máximo (múltiplos de 45º).

Detecção de bordas por compass operator
Método Kirsh



- Na prática, o método de Kirsh fornece resultados bastante parecidos aos dos filtros de gradiente.

- Por isso, para aplicações em geral, o método de Sobel é mais popular que os baseados em compass masks.

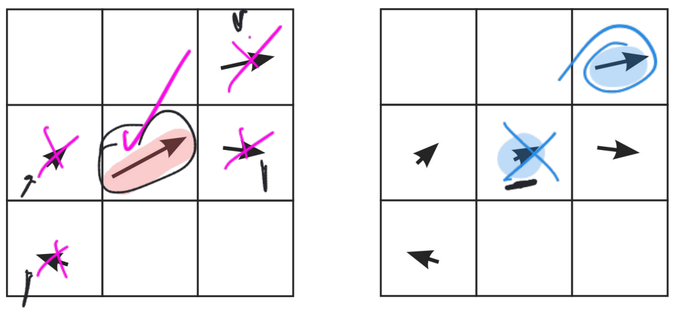
Detecção de bordas
Método Canny

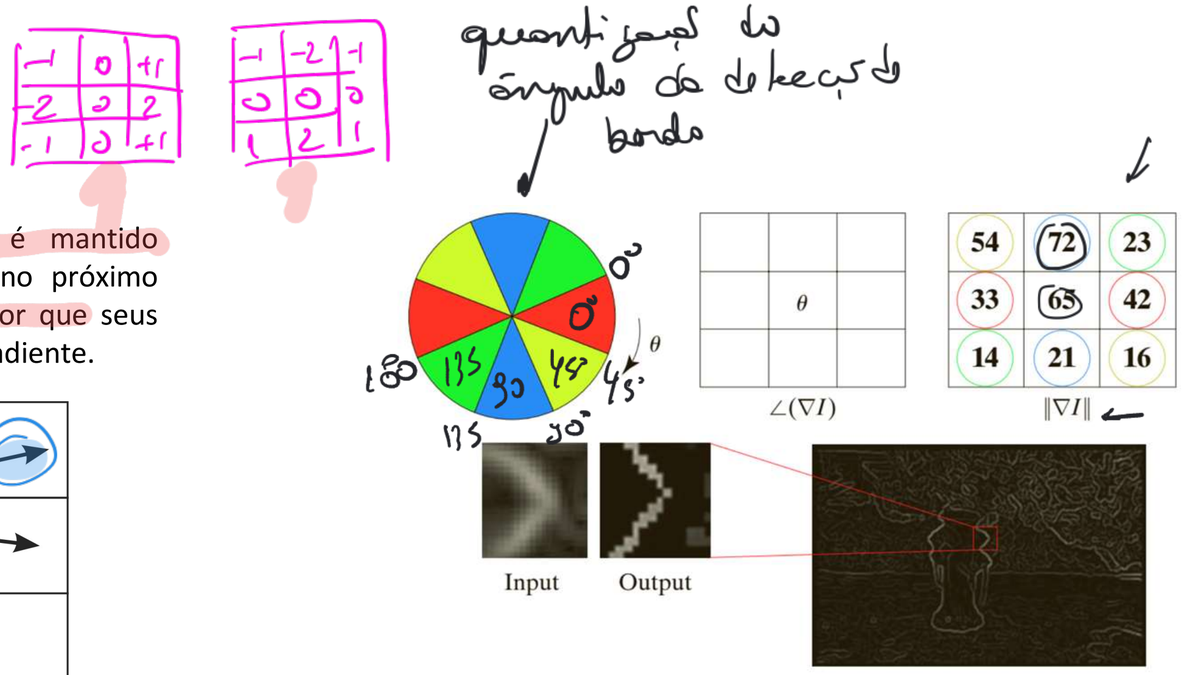
- É o mais utilizado.
- É basicamente um método para limiarizar a magnitude do gradiente.
- Há muitas variações da implementação. Uma possibilidade:

1) **LPF** usando o Gaussiano.

2) Calcula **magnitude e direção do gradiente** usando máscaras Sobel.

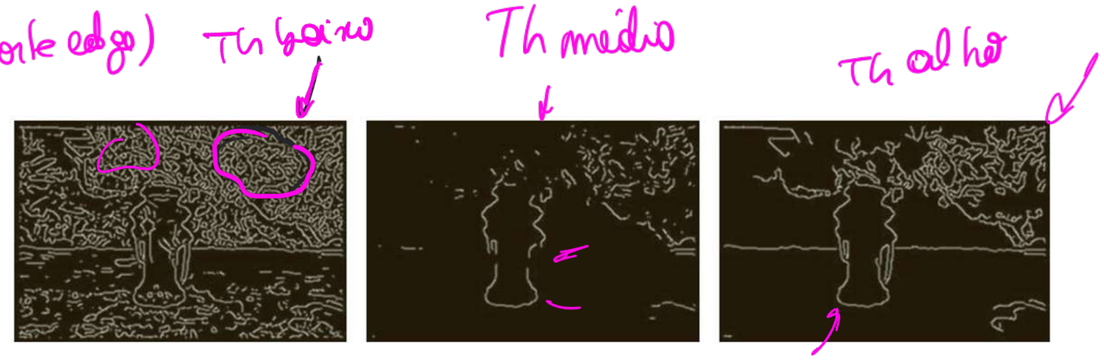
3) **Non-maximum supression**: um pixel só é mantido (considerado potencial borda e analisado no próximo passo) se tiver magnitude do gradiente maior que seus vizinhos determinados pela direção do seu gradiente.





4) **Histeresys threshoding**: Limiares T_L e T_H
   Se > T_H → strong edge
   Se entre T_L e T_H → weak edge

5) **Edge linking**: incorpora pixels de weak edge dentro de uma vizinhança 8 de um pixel de strong edge.



Stan Birchfield, Image Processing and Analysis, Cengage Learning, 2018, Figures 7.10, 7.11

Detecção de bordas
Método Canny

